

INSTITUTO POLITÉCNICO NACIONAL



PROFESOR : M. en C. Edmundo René Durán Camarillo.

MATERIA : Sistemas Neurodifusos II.

TEORÍA DE RESONANCIA ADAPTATIVA (REDES ART)

EQUIPO :

- Maldonado Orduño Jessie.
- Munguía Solache Martha.
- Ruíz Hidalgo Héctor Alejandro.

FECHA : 2 de abril de 2002.

INDICE :

Pág.

TEORIA DE RESONANCIA ADAPTATIVA

1.INTRODUCCIÓN :

El hecho que condujo a la concepción de las redes ART fue lo que se conoce como el **dilema de la estabilidad y plasticidad del aprendizaje**. Este dilema surge a partir de dos ideas:

- Una red neuronal debe poder aprender nuevos patrones, es decir, debe tener cierta **plasticidad de aprendizaje**.
- Una red neuronal debe poder recordar los patrones ya aprendidos, es decir, ser **estable** aún cuando se le introduzcan datos que no sea capaz de reconocer.

Sin embargo estas dos características son difíciles de implementar juntas, pues al aprender nuevos patrones, se corre el riesgo de perder los ya memorizados, igualmente, si se mantienen firmemente memorizados unos patrones iniciales, se dificulta el aprendizaje de nuevos patrones, comprometiendo su capacidad de adaptarse a condiciones nuevas.

Grossberg, Carpenter y un grupo de colaboradores desarrollaron su **teoría de resonancia adaptativa** para resolver este dilema, la cual se aplica a redes con aprendizaje competitivo, en las cuales solo una neurona o una neurona de un grupo, después de competir con otras, reacciona con su máximo nivel de respuesta al presentarse determinado patrón de entrada. Se dice que esta neurona es la *vencedora*, de esta manera la red busca crear categorías (clusters), según los datos que se le introduzca. La red debe decidir a que categoría pertenece cada dato que se le presente según su parecido con alguna categoría definida, y si no hay un grado de similitud lo suficientemente grande, la red creará una categoría nueva tomando como modelo el nuevo patrón. Se deduce de esto que el aprendizaje en las redes ART es no supervisado.

A estas redes se les ha agregado un mecanismo especial de realimentación entre las neuronas de la capa de salida (competitivas) y las de la capa de entrada; lo cual contribuye a mantener la plasticidad y la estabilidad de la red.

La teoría de resonancia adaptativa se basa en el hecho de que la información de alguna de las categorías almacenadas en la red debe **"resonar"** si se presenta una información similar en la entrada. Si es este el caso, la red reconocerá la información y adaptará su modelo para que se parezca mas al patrón de entrada. De lo contrario, la red creará una nueva categoría tomando como modelo el patrón de entrada presentado.

Grossberg, Carpenter et al. propusieron dos redes basadas en este modelo :

- ART o ART1 (1986) a la cual se presentan patrones de entrada binarios y;
- ART2 (1987) para trabajar con información analógica.

2. TIPOS DE REDES ART :

Hay dos grandes ramas de redes ART: las ART1 que trabajan con vectores de información binaria y las redes ART2, que procesan información analógica. Sin embargo con el desarrollo de las redes neuronales, de la computación y de las nuevas aplicaciones han surgido varios subgrupos de redes ART:

- ♠ **ART-2^a** : Es una versión más rápida del algoritmo de redes ART2.
- ♠ **ART-3** : Extensión de red ART que incorpora transmisores químicos para controlar el proceso de búsqueda de categorías dentro de la red.
- ♠ **ARTMAP** : Es una versión supervisada de ART que puede aprender mapas de patrones binarios.
- ♠ **Fuzzy ART** : Síntesis de lógica difusa y redes ART.
- ♠ **Fuzzy ARTMAP** : Es una red Fuzzy ART supervisada

3. ADAPTACIONES DE REDES ART:


- ♠ **ARTMAP-IC** : Sistema ARTMAP con la adición de predicción distribuida y conteo de instancia de categoría.
- ♠ **Gaussian ARTMAP** : Una red ART con aprendizaje supervisado que emplea campos receptivos (Gauss).
- ♠ **Modelos ART jerárquicos (modulares)** : Estas redes modulares basadas en ART aprenden categorías jerárquicas de secuencias arbitrarias de patrones de entrada.
- ♠ **ArboART** : En esa red los prototipos de cada capa se emplean como entradas de la capa siguiente. Este método se conoce como método aglomerativo. La arquitectura es similar a las redes HART-J, descritas mas abajo. Se ha aplicado en la generación de reglas automáticas de los sistemas expertos de Kansei Engineering.
- ♠ **Cascade Fuzzy ART** : Como su nombre lo indica, es una serie de redes FuzzyART conectadas en cascada que generan jerarquías de patrones análogos y binarias mediante un aprendizaje de "arriba a abajo" pero con un proceso de búsqueda de "abajo hacia arriba". Se ha aplicado en el reconocimiento de objetos tridimensionales.
- ♠ **HART(-J), HART-S** : Modelos ART jerárquicos y modulares. HART-J emplea el método de categorización aglomerativa. HART-S emplea un método de categorización divisiva, con cada capa ART aprendiendo las diferencias entre la entrada y el prototipo semejante de la capa previa.
- ♠ **SMART** : Self-consistent Modular ART (ART modular autoconsistente). Es capaz de aprender jerarquías de categorías autoconsistentes a través de enlaces explícitos y un mecanismo interno de realimentación.
- ♠ **LAPART** : Arquitectura basada en ART para la verificación de secuencias de patrones a través de inferencia.
- ♠ **MART** : ART multicanal, para la clasificación adaptativa de patrones a través de múltiples canales de entrada.
- ♠ **PROBART** : Una modificación de una red Fuzzy ARTMAP por la construcción de información probabilística mediante asociaciones entre

nodos de capas distintas, lo que le permite aprender con cierta aproximación mapas ruidosos.

- ♣ **R2MAP** : Red basada en ARTMAO capaz de aprender tareas de clasificación complejas mediante la creación iterativa de características relacionales de las entradas para representar el mismo problema con menos categorías de entradas. Se motiva en la hipótesis de redescipción representacional, de las ciencias cognitivas.
- ♣ **TD-ART** : Red ART con retardos en el tiempo para el aprendizaje de patrones espacio-temporales.

4. ARQUITECTURA :

Una red ART esta compuesta por una capa de entrada con N neuronas y una de salida con M neuronas. Entre ambas se presentan conexiones feedback y feedforward. Las neuronas de la capa de salida se encuentran interconectadas y presentan conexiones autorrecurrentes.



En la capa de salida los pesos son fijos, siendo 1 los de las conexiones autorecurrentes y $-\epsilon$ en las conexiones laterales. Este valor negativo contribuye a la competitividad entre las neuronas de esta capa, y debe ser menor que $1/M$. En los pesos de las conexiones feedforward y feedback, definidos como w_{ji} y v_{ij} , se va a almacenar la información de la red.

Sin embargo una red ART no puede ser descrita con un modelo sencillo de red de dos capas, como en la figura anterior. El modo de funcionamiento de la red determina la existencia de dos subsistemas: el de *atención* y el de *orientación*.

4.1. El Subsistema de Atención :

El subsistema de atención consiste básicamente en el reconocimiento y clasificación de las informaciones aprendidas. En este subsistema se localiza la memoria a largo plazo de la red (LTM)(Long Term Memory), compuesta por los pesos W_{ji} y V_{ij} de las conexiones entre las neuronas de las capas de entrada y salida, que confieren a la red su característica de estabilidad, en el sentido de retener las informaciones aprendidas. Como complemento a la anterior, existe también una memoria a corto plazo (STM)(Short Term Memory), localizada en la entrada y en la salida de la red, que se refiere a la capacidad de recordar aspectos más inmediatos mediante la retención temporal de los valores de entrada en las neuronas que componen las capas de entrada y salida.


Otra parte del subsistema de atención, es el **control de ganancia de atención**, que actúa sobre las neuronas de entrada (STM(ne)) para estabilizar el funcionamiento de la red, aumentando la sensibilidad o grado de atención de estas neuronas, evitando una posible anticipación respecto a la llegada de la información del siguiente patrón a través de las conexiones feedback (V_{ij}).

Aunque no lo consideramos, puede existir otro control de ganancia que, en función de las salidas de las neuronas de la capa de entrada, actúe sobre las de salida para mejorar su reacción ante los patrones de entrada.

4.2. El Subsistema de Orientación :

El subsistema de orientación se utiliza para detectar si la información de entrada pertenece o no a una determinada categoría conocida por la red, para lo cual se calcula el porcentaje de semejanza entre dicha información y el representante (prototipo) de cada categoría almacenada en los pesos V_{ij} (LTM), que deberá ser superior al valor de un parámetro p , denominado **parámetro de vigilancia**. Si no es así este subsistema resetea la neurona vencedora de la capa de salida y prueba con otra categoría. Si ninguna es suficientemente parecida se crea una nueva clase, de la que será prototipo la información de entrada. Por tanto, el subsistema de atención realiza la tarea de reconocimiento (búsqueda de la salida a la que pertenece la entrada), mientras que el subsistema de orientación actúa sobre el primero, permitiéndole responder a entradas no pertenecientes a ninguna categoría, creando para ellas nuevas clases.


Entonces la arquitectura simplificada, debería ser completada añadiendo dos neuronas que permitan implementar las funciones de control de ganancia y del subsistema de atención. La estructura completa de la red sería la indicada en la siguiente gráfica:



Aquí, el nodo reset (R) tiene un funcionamiento especial: su misión es recibir las salidas de las neuronas de entrada a través de conexiones con peso -1 junto con los valores del patrón de entrada a la red a través de conexiones con pesos iguales al parámetro de vigilancia de la red, para compararlo, y si no son suficientemente parecidos, activar la salida correspondiente para, a través de una conexión de inhibición con peso negativo de gran valor ($-N$), conseguir anular el efecto de las neuronas que se ha comprobado que no representan la categoría adecuada para el patrón de entrada.

La neurona G es la que permite el control de ganancia de atención. Para ello recibe como entrada los valores de las neuronas de las capas de salida a través de conexiones con pesos $-N$ y los del patrón de entrada mediante conexiones con peso igual a la unidad, generando, mediante una función de activación escalón, una salida que se aplicará a las neuronas de la capa de entrada de la red para ayudar a la activación de las neuronas de esta capa en función de la cantidad de neuronas de salida activadas. De esta forma se puede aplicar la regla de activación denominada Regla 2/3, que indica que una neurona de la capa de entrada se activará (salida 1) cuando 2 de las 3 entradas que recibe (patrones de entrada, neurona G y conexiones v_{ij}) esté activa (tenga valor 1).


La salida generada por la neurona G, que va a tener un umbral de valor $\frac{1}{2}$ es:



La entrada neta de cada neurona de la capa de entrada es:

$$net_{ne_i} = e_i^k + \sum_{j=1}^M v_{ij} s_{ns_j} + s_G$$

Por tanto, la salida general por cada neurona de entrada, considerando un umbral de 1.5 es:



Pero al trabajar con valores binarios (1/0) y con los umbrales indicados queda:

$$S_{ne_i} = \begin{cases} e_i^k & \text{Si ninguna salida esta activada } (s_{sn_j} = 0 \quad \forall_j) \\ e_i^k \cdot \sum_{j=1}^M v_{ij} s_{ns_j} & \text{En otro caso} \end{cases}$$

En cuanto al nodo de reset (R), este va a tener M salidas, una por neurona de la capa de salida de la red, de las cuales se podrá activar una cada vez, la correspondiente a la neurona a resetear.

Su función de activación será:

$$S_R = \begin{cases} \text{Reset de } ns_j & \sum_{i=1}^N (\rho e_i^k - s_{ne_i}) > 0 \\ 0 & \sum_{i=1}^N (\rho e_i^k - s_{ne_i}) \leq 0 \end{cases}$$

siendo ρ el parámetro de vigilancia:

$$\sum_{i=1}^N \left(\frac{s_{ne_i}}{e_i^k} \right) < \rho$$

Este nodo R se podría implementar como un conjunto de M neuronas (R1....RM) que reciben las mismas entradas. Las salidas de cada una de estas neuronas (Rj) se conectaría a la entrada de la correspondiente neurona de la capa de salida de la red (nsj) a través de conexiones con un peso negativo de un gran valor con una función de transferencia de tipo escalón, pero con un umbral dependiente del valor de salida de la neurona de la red a la que esta conectada, de tal forma que si es la neurona ganadora, se podrá producir el reset, lo que consigue mediante la activación de la neurona Rj, se inhiba a nsj. El resto de las neuronas de r generarán una salida de valor 0. Puede comprobarse que esto se consigue si el umbral de la función de activación de cada neurona Rj fuese $\theta_j = N(1 - s_{nsj})$.

5.FUNCIONAMIENTO:

El funcionamiento de una red ART puede describirse de forma simplificada a través de la siguiente secuencia de pasos:

- 1) Se presenta una información (vector) de entrada a la red:

$$E_k = (e_1^k, \dots, e_N^k)$$

- 2) Cada neurona (nei) de la capa de entrada recibe el valor del componente correspondiente (e_i^k) del vector y lo envía a todas las neuronas de la capa de salida a través de las conexiones correspondientes (w_{ji}).
- 3) Cada neurona (nsj) de la capa de salida compite con las demás de esta capa hasta que solo una permanece activa. Las conexiones laterales son las que permiten realizar esta competición, y tienen un peso con un valor fijo $-\epsilon$ que debe ser menor que $1/M$, siendo M el número de neuronas de la capa de salida, para que la competición funcione correctamente:

$$S_{ns_j}(t+1) = f \left[s_{ns_j}(t) + \epsilon \sum_{p=1}^N s_{ns_p}(t) + \sum_{i=1}^N w_{ji} s_{ne_i}(t) \right]$$

Siendo f la función de transferencia de tipo escalón de las neuronas de salida.

Después de cierto número de iteraciones, se llega a una situación de estabilidad en que una de las neuronas resulta vencedora, generando una salida de valor 1, mientras que en las demás salidas la salida es 0. Como los pesos de las conexiones laterales de inhibición tienen el mismo valor (-épsilon), así como las autorrecurrentes (+1), es evidente que el factor a tener en cuenta para saber cual es la neurona vencedora será la entrada que recibe cada neurona a través de las conexiones *feedforward* con pesos w_{ji} provenientes de la capa de entrada. Así los valores de salida al final de la competición se pueden obtener más fácilmente mediante la siguiente expresión:

$$s_{ns_j} = 1 \text{ } ______ \text{ } MAX \left(\sum_{i=1}^n w_{ji} e_i^{(k)} \right)$$

$$s_{ns_j} = 0 \text{ } ______ \text{ } resto$$

- 4) La neurona vencedora (ns_j), envía su salida (1) a través de las conexiones hacia atrás (v_{ij}). Cada neurona i -ésima de la capa de entrada recibe el valor:

$$x_i = \sum_{j=1}^M v_{ij} s_{ns_j} = v_{ij} \quad \text{porque} \quad \begin{aligned} s_{ns_j} &= 1 \text{ } ______ \text{ } j = j^* \\ s_{ns_j} &= 0 \text{ } ______ \text{ } j \neq j^* \end{aligned}$$

Por tanto, al no influir el resto de las neuronas de salida por estar inactivas (0), en la capa de entrada se reciben los valores de los pesos de las conexiones correspondientes.

- 5) Se compara la información de entrada

$$E_k = (e_1^{(k)}, \dots, e_N^{(k)})$$

Con la información

$$X = (x_1, \dots, x_N) = (v_{1j^*}, \dots, v_{Nj^*}) = V_{j^*}$$

Recibida en la capa de entrada desde la salida a través de las conexiones hacia atrás. Hay que resaltar que el valor X (y por tanto v_j) es en realidad el representante o prototipo de la clase o categoría j -ésima si la neurona que se ha activado, la vencedora, ha sido la neurona de salida ns_j . Esta comparación se hace valorando la siguiente relación de semejanza:

$$Relacion_de_semejanza = \frac{\|E_k \cdot X\|}{\|E_k\|} = \frac{\|E_k \cdot V_j\|}{\|E_k\|}$$

$$\| E_k \cdot X \| = \sum_{i=1}^N e_i^{(k)} x_i$$

$$\| E_k \| = \sum_{i=1}^N e_i^{(k)}$$

Al trabajar con valores binarios (0/1), el producto aritmético equivale al lógico (operación AND), y por tanto, lo que representa $\|E_k X\|$ es el número de componentes binarios (bits) con valor 1 que coinciden en los vectores E_k y X . En caso de que fueran exactamente iguales, este valor coincidiría con $\|E_k\|$, y la relación de semejanza sería la unidad (el parecido es del 100%). Si E_k y X no coinciden en ningún bit, entonces $\|E_k X\|=0$ y el parecido sería del 0%.

- 6) Se compara la relación de semejanza entre ambas informaciones con un *parámetro de vigilancia* (ρ) cuyo valor será fijado por el usuario en un rango de 0 a 1 y que influirá en el número de clases que establecerá la red, ya que cuanto mayor sea su valor, se está pidiendo al sistema que discrimine con mayor precisión, de tal forma que si $\rho=1$ se estará indicando que a una clase solo pueden pertenecer patrones que sean exactamente iguales.

Si se cumple que:

$$\frac{\| E_k \cdot X \|}{\| E_k \|} < \rho$$

Entonces la neurona vencedora nsj , no representa la apropiada categoría a la que pertenece la información de entrada E_k y es desestimada, se *resetea* o elimina del conjunto de posibles neuronas vencedoras. Esto puede hacerse como se indicó en el apartado anterior mediante un nodo adicional (R) que actúe sobre nsj , a través de una conexión de fuerte inhibición, con peso negativo de gran valor absoluto.

En este punto se pueden dar dos situaciones:

- a) Si todavía quedan neuronas de salida que no hayan sido desestimadas, se repite el proceso de búsqueda de la categoría a la que pertenece la entrada (paso 2) anulando (*reseteando*) temporalmente la neurona vencedora para que no influya en la repetición del proceso de competición.
- b) Si no queda ninguna neurona candidata por que ya se ha repetido el proceso, considerando como vencedoras cada una de las neuronas de salida, entonces se produce una situación de saturación de la red, ya que no se puede crear una nueva categoría para el patrón, al no existir ninguna neurona de salida que pueda asociarse a la nueva clase. Podría solucionarse el problema ampliando el número de neuronas de salida de la red de forma dinámica, ya


que los nuevos pesos no afectarían representantes ya almacenados en el resto de conexiones (w_{ji} , v_{ij}) que componen la memoria a largo plazo de la red. En este caso si se amplía en una unidad se inicializan los pesos de las nuevas conexiones, y se repite el proceso desde el paso 4. Como inicialmente los pesos tienen el valor 1, la relación de semejanza será del 100% con lo que se estaría en la situación prevista en el paso 7 que se describe a continuación.

- 7) Si la semejanza evaluada es igual o mayor que el *parámetro de vigilancia*, entonces

se asume que la neurona que se ha activado a la salida es la que representa la categoría mas apropiada para la información de entrada E_k , procediéndose a ajustar los pesos v_{ij} y w_{ji} de la red (*memoria a largo plazo*) para que el nuevo prototipo almacenado para representar dicha categoría incorpore algunas características del dato de entrada. Como la red descrita trabaja con datos binarios, esto consiste en una operación lógica AND entre los bits del prototipo (v_{ij}) y los del patrón de entrada (e_i^k). Por este motivo inicialmente los pesos v_{ij} se inicializan a 1, para que cuando se almacene el primer representante de cada clase, el prototipo coincida exactamente con el patrón de entrada.

En realidad la secuencia de pasos descrita viene a decir que *cuando entra en funcionamiento una red ART se produce una búsqueda a través de los prototipos almacenados y asociados a cada clase o categoría, con la pretensión de encontrar uno lo suficientemente parecido a la información presentada a la entrada de la red. Si esta categoría no existe, se crea una nueva, la cual es prototipo de dicha información.*

La red ART por lo tanto permite establecer clases de datos. Recibiendo datos de entrada y activando la salida que indique la categoría o clase a la que pertenece. Si en la capa de salida hay N neuronas, el numero de categorías que se establecen es N. Los prototipos o representantes de las clases son los pesos v_{ij} de las conexiones. Para extraerlos de la red, se puede añadir una nueva capa de neuronas a la salida con un numero de neuronas igual al de la capa de entrada, y con pesos iguales a los anteriores (v_{ij}).



Ampliación de la red ART para la extracción de prototipos.

6. APRENDIZAJE :

El aprendizaje en el modelo ART es de tipo ON LINE, por lo que no se distingue entre etapa de entrenamiento y de funcionamiento. Los pesos varían durante el funcionamiento de la red cuando se aplica una información de entrada a la misma.

La red ART utiliza un *aprendizaje no supervisado de tipo competitivo*. Las neuronas de la capa de salida compiten por activarse y solo una de ellas permanece activa ante una determinada entrada a la red. Los pesos de las conexiones se ajustan en función de la neurona que haya resultado ganadora.

En este tipo de redes se pueden dar dos tipos de aprendizaje, denominados *aprendizaje lento* y *aprendizaje rápido*. El aprendizaje lento ocurre cuando una información de entrada es asociada a una de las categorías existentes. Entonces se debe proceder a ajustar los pesos para que el representante de dicha clase se adapte a las características del dato de entrada. El aprendizaje rápido se da cuando se establece una nueva categoría, y consiste en representar de forma inmediata la información de entrada, que será el prototipo de la nueva clase, en los pesos de la red.

Inicialmente, cuando la red no ha *aprendido* todavía ninguna información, se asigna el valor 1 a los pesos de las conexiones hacia atrás (v_{ij}).

En estos pesos se distribuyen los M prototipos de las M diferentes clases que es capaz de diferenciar la red. Los pesos de las conexiones hacia delante (w_{ji}) tienen el mismo valor que los v_{ij} pero normalizado:

$$w_{ji} = \frac{v_{ij}}{\gamma + \sum_{i=1}^N v_{ij}}$$

γ es un valor pequeño, normalmente se utiliza 0.5, aunque en la inicialización de los pesos se recomienda como valor la unidad. Por tanto, inicialmente el valor de pesos es:

$$v_{ij}(t=0) = 1$$

$$w_{ji}(t=0) = \frac{1}{1+N}$$

Después, cada vez que se presente una información

$$E_k = (e_1^{(k)}, \dots, e_N^{(k)})$$

A la red, se realiza el *aprendizaje* o ajuste de los pesos de las conexiones v_{ij} , de la neurona vencedora con cada una de las N de la capa de entrada, en función de la diferencia entre esta información y la del representante o prototipo de la clase a la que se ha asociado. En general la variación de los pesos v_{ij} se realiza según la siguiente ecuación diferencial:

$$\frac{dv_{ij}}{dt} = s_{ns_j} (s_{ne_i} - v_{ij})$$

Si la neurona de salida ns_j no es la vencedora, el valor de su salida es cero ($s_{ns_j}=0$), con lo que no debe producirse variación en el peso correspondiente ($dv/dt=0$). Por el contrario, si la neurona es la vencedora, su salida es 1 ($s_{ns_j}=1$), con lo que la variación del peso v_{ij} , sería

$$\frac{dv_{ij}}{dt} = (v_{ij}^* e_i^{(k)} - v_{ij}^*)$$

Según esta expresión, el nuevo valor del peso se obtendría como:

$$v_{ij}^*(t+1) = v_{ij}^*(t) e_i^{(k)}$$

Siendo $e_i^{(k)}$ el valor del componente i -ésimo de la información de entrada. Los pesos w_{ji} se obtienen normalizando los anteriores:

$$w_{ji}^*(t+1) = \frac{v_{ij}^*(t) e_i^{(k)}}{\gamma + \sum_{i=1}^N v_{ij}^*(t) e_i^{(k)}}$$

Donde γ suele tener el valor de 0.5.

7. LIMITACIONES DE LA RED ART :

Aunque la red ART es una de los más potentes modelos con capacidad autoorganizativa, sin supervisión, existen algunas limitaciones importantes a tener en cuenta que dificultan la tarea de clasificación realizada por la red. Estas limitaciones se refieren, sobre todo, a su dependencia del respecto del tipo y orden de las informaciones aprendidas y a la influencia del parámetro de vigilancia en él número de categorías creadas por la red, ya que pequeños cambios de este parámetro pueden originar un gran número de categorías.

Se trata de una red con gran sensibilidad ante el ruido o distorsión, también ante el desplazamiento de los datos de entrada, que pueden dar lugar a una gradual

También este modelo presenta el problema de la ineficiencia en cuanto a las necesidades requeridas para el almacenamiento de los pesos de las conexiones entre neuronas. Hay que tener en cuenta que se precisan $2 \cdot N$ para representar cada categoría de N bits, además de las conexiones laterales y autorrecurrentes de la capa de salida y las de las neuronas espaciales de orientación (R) y control de ganancia (G).

8. LA RED ART2 :

Estructura de una red ART-2

Esta red se diferencia de la ART(ART1) en la capacidad para tratar tramas analógicas. Aparte del hecho evidente en que las tramas binarias y las analógicas difieren en la naturaleza de sus componentes respectivos, la ART2 debe enfrentarse a complicaciones adicionales; debe ser capaz de reconocer la similitud subyacente de tramas idénticas que se superpongan a fondos constantes que posean distintos niveles. Comparadas en un sentido absoluto, dos tramas como éstas pueden tener un aspecto completamente distinto, aun cuando lo cierto es que deberían ser clasificadas como una misma trama. El precio de esta capacidad adicional es sobre todo un aumento de complejidad en el nivel de procesamiento de la capa de entrada, es decir que el nivel de la capa de entrada consta ahora de varios subniveles y varios sistemas de control de ganancia.

9. APLICACIONES :

Las redes ART se han utilizado, entre otras, en las siguientes aplicaciones:

- **Reconocimiento de imágenes:** Para este fin, se divide la imagen en píxeles y se crea con ellos una matriz que alimentara la entrada de la red. La gran capacidad de categorización de las redes ART hacen que aplicaciones concretas en este campo, como son el reconocimiento de caracteres sean de gran efectividad.
- **Reconocimiento de señales análogas:** Para este fin se emplean redes ART2 (entradas y salidas análogas). Las aplicaciones concretas en este campo son el reconocimiento de voz y el reconocimiento de señales de electrocardiogramas para el diagnostico de enfermedades cardiacas, entre otras.
- **Reconocimiento de olores ("nariz electrónica"):** A simple vista esto puede parecer una broma, pero los investigadores Paul E. Keller, Lars J. Kangas, Lars H. Liden, Sherif Hashem y Richard T. Kouzes han realizado investigaciones en este campo y han obtenido un prototipo de "nariz electrónica": Este tipo de dispositivos se ha desarrollado para el reconocimiento de olores, gases y vapores presentes en el aire. Esta compuesto por un sensor químico y un sistema de reconocimiento de patrones (red neuronal artificial, por supuesto). Se han empleado redes backpropagation y *fuzzy ARTmap*. Las aplicaciones de este tipo de dispositivos no son pocas:
 - En el campo ambiental, se están utilizando para la detección sustancias tóxicas, emisiones de fabricas, monitoreo de la calidad del aire, detección de derrames etc.
 - En la medicina se puede emplear en el diagnostico de enfermedades mediante el análisis del aire exhalado, y emanaciones provenientes de fluidos corporales como la sangre u orines.
 - En la industria alimenticia esta empleando este dispositivo para la inspección de la calidad de los alimentos según su olor, control de fermentación, etc.

10. BIBLIOGRAFÍA:

- <http://maxwell.univalle.edu.co/proyectos/rna/>
- <http://maxwell.univalle.edu.co/proyectos/rna/ART1/>
- <http://maxwell.univalle.edu.co/proyectos/rna/ART1/>
- <http://maxwell.univalle.edu.co/proyectos/rna/ART1/>
- <http://maxwell.univalle.edu.co/proyectos/rna/ART2/>
- http://maxwell.univalle.edu.co/proyectos/rna/ART2/texto_arqART1.html
- <http://maxwell.univalle.edu.co/proyectos/rna/ART2/1.2.subsistema.de.orientacion1.html>
- <http://maxwell.univalle.edu.co/proyectos/rna/ART2/funcionamiento.html>
- <http://maxwell.univalle.edu.co/proyectos/rna/ART2/aplicacion.html>
- <http://www.wi.leidenuniv.nl/art/>
- <http://www.nd.com/appcornr/purpose.htm>
- <http://www.emsl.pnl.gov:2080/proj/neuron/neural/>
- <http://www.ism.ac.ru/nn/doc/nbdoc/koi8/art1.htm>
- <http://www.mcs.vuw.ac.nz/comp/Publications/CS-TR-94-1.abs.html>
- <http://www.ie.inf.uc3m.es/Tesis/Documentos/ProcesosSoftware/RedesNeuronales/MejoraRedesNeuronales.html>