

**MODELO ADAPTATIVO DE INTELIGENCIA ARTIFICIAL
PARA EL DIAGNÓSTICO AUTOMÁTICO DE FALLAS
A PARTIR DE REGISTROS DE OSCILOPERTURBOGRAFIA**

**Tesis de Maestría en Ingeniería de Sistemas
Línea de Investigación en Inteligencia Artificial**

ING. JHON ALBEIRO CALDERON SERNA MSc (C).

Director: GERMAN ZAPATA MADRIGAL. MSc.

Codirector: DEMETRIO ARTURO OVALLE CARRANZA Ph.D.



**UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE MEDELLIN
FACULTAD NACIONAL DE MINAS
POSTGRADO EN INGENIERIA DE SISTEMAS
MEDELLÍN, NOVIEMBRE DE 2007.**

RESUMEN

El presente informe aborda el Diagnóstico Automático de Fallas (DAF) a partir de registros de osciloperturbografía de eventos que se presentan en un Sistema Eléctrico de Potencia (SEP). El reto de este diagnóstico se relaciona con el hecho de que ningún registro nuevo es igual a otro que se haya presentado en el pasado. Por ello, para afrontarlo, se precisa de modelos inteligentes y adaptativos, que aprendan de las experiencias para mejorar su desempeño en el tiempo y se adapten a las condiciones exigidas por un SEP real.

De la exploración al estado del arte sobre el tema se pudo determinar que, las propuestas, en general, son válidas para condiciones específicas de algunos SEP pero falta aún profundizar e investigar en torno de la variación esperada de las condiciones eléctricas en cualquier SEP real del mundo.

Para dar solución a los inconvenientes planteados se propone: un Modelo Adaptativo de Inteligencia Artificial (MAIA), una Metodología de Entrenamiento y Validación Adaptativa (MEVA) y un Sistema Basado en Conocimiento (SBC) para integrar el DAF. La propuesta se inspira en dos aspectos del cerebro humano: el hardware ó conocimiento almacenado en sistemas conexionistas (redes neuronales y Teoría de Resonancia Adaptativa: entrenadas y validadas con MEVA) para reproducir capacidades asociadas a la inteligencia de bajo nivel, para reconocimiento de patrones (MAIA) y el software ó conocimiento intuitivo de más alto nivel, como el razonamiento aproximado (SBC).

Finalmente, todo este conjunto MAIA + SBC se entrena y valida mediante MEVA con 46996 casos simulados y alrededor de 3600 registros reales de la red de Interconexión Eléctrica S.A.

ABSTRACT

The present report boards the Automatic Fault Diagnosis (AFD) using fault records captured from the Electrical Power System (EPS). The challenge of this diagnosis is related with the fact of that no any new fault record is equal to another that it have presented in the past. Hence, for confronting it, is necessary to use intelligent and adaptive models that learn of the experiences for improving his performance in the time and himself adapting to the conditions required for an actual EPS.

From the exploration to the status of the art about this topic was able to determine that, the proposals, in general, are valid for specific conditions of some EPS but still lacks to deepen and investigate around of the expected variation of the electrical conditions in any actual ESP in the world.

For giving solution to these disadvantages is proposed: an Artificial Intelligence Adaptive Model (AIAM), an Adaptive Training and Validation Methodology (ATVM) and a Knowledge Based System (KBS) for integrating the AFD.

The proposal is inspired in two aspects of the human brain: the hardware or knowledge stored in connectionism systems (neural networks and Adaptive Resonance Theory: trained and validated with ATVM) for reproducing associated capacities to the low level intelligence for pattern recognition (AIAM) and the software or intuitive knowledge of top level like the approximate reasoning (KBS).

Finally, this everything whole AIAM + KBS is trained and validated by ATVM with 46996 simulated cases and about of 3600 actual records from Interconexión Eléctrica S.A.

A mi esposa Nidia, a mis hijos John Albeiro y María Yesenia y a mis padres Jairo y Esperanza por su comprensión y apoyo.

AGRADECIMIENTOS

Esta investigación hace parte del proyecto ISA-Colciencias-Universidad Nacional que fue formulado ante COLCIENCIAS por parte de Interconexión Eléctrica S.A. E.S.P. como entidad beneficiaria y ejecutora y la Universidad Nacional de Colombia sede Medellín como entidad ejecutora. Este proyecto pretende automatizar el proceso de diagnóstico automático de fallas en un sistema de transmisión de energía.

Deseo expresar mis más sinceros agradecimientos a mi director Germán Zapata Madrigal y codirector Demetrio Arturo Ovalle Carranza por sus aportes, guía y soporte.

Además, deseo agradecer a los miembros del grupo del proyecto: A Leonardo Vásquez Ruiz como director del proyecto por parte de ISA, a Luis Everley Llano como compañero de motivación y ánimo y de manera muy especial a Andrés Hoyos, Julián Moreno y Luis Quintero por el excelente apoyo recibido.

TABLA DE CONTENIDO

RESUMEN	1
ABSTRACT.....	1
INDICE DE FIGURAS.....	IV
INDICE DE TABLAS.....	VI
CAPITULO 1	1
INTRODUCCION	1
1.1 INTRODUCCIÓN	1
1.2 APORTES.	2
1.3 DIFUSIÓN DE RESULTADOS.	2
<i>Internacional</i>	2
<i>Nacionales</i>	2
1.4 MOTIVACIÓN	3
1.5 EXPLORACIÓN DE LA PROBLEMÁTICA.	4
CAPITULO 2	8
ANTECEDENTES.....	8
2.1 TRABAJOS PREVIOS.	8
2.1.1 <i>Proyectos de Investigación y Desarrollo</i>	8
2.1.2 <i>Trabajos Dirigidos de Grado</i>	9
2.2 ESTADO DEL ARTE.	10
2.3 COMUNIDAD CIENTÍFICA.	10
2.4 PRINCIPALES REVISTAS DEL TEMA.	11
CAPITULO 3	12
ALCANCE Y DEFINICIÓN DEL PROBLEMA DE INVESTIGACIÓN	12
3.1 LIMITACIONES ENCONTRADAS EN EL ESTADO DEL ARTE.	12
3.2 REQUERIMIENTOS DEL SISTEMA ELÉCTRICO DE POTENCIA.	12
3.3 CONSIDERACIONES DE TIPO PRÁCTICO.....	13
3.4 DEFINICIÓN DEL PROBLEMA DE INVESTIGACIÓN.	13
3.5 HIPÓTESIS.	13

3.6	PREGUNTAS DE INVESTIGACIÓN.....	14
3.7	OBJETIVO GENERAL.....	14
3.8	OBJETIVOS ESPECÍFICOS.....	14
CAPITULO 4.....		15
PROPUESTA METODOLOGICA.....		15
4.1	FASE 1: PREPARAR DATOS.....	15
4.2	FASE 2: EXTRAER LAS COMPONENTES PRINCIPALES DEL SEP.....	15
4.3	FASE 3: ANALIZAR, DISEÑAR Y CONSTRUIR UN PROTOTIPO DEL MODELO MAIA.....	16
4.4	FASE 4: ENTRENAR, VALIDAR Y CHEQUEAR EL PROTOTIPO DEL MODELO MAIA.	18
4.5	FASE 5: DISEÑAR, CONSTRUIR Y VALIDAR EL SISTEMA BASADO EN CONOCIMIENTO (SBC). .	18
CAPITULO 5.....		19
PREPARACION DE LOS DATOS		19
5.1	SELECCIÓN TÉCNICA DEL FILTRADO ANALÓGICO.	19
5.2	SELECCIÓN TÉCNICA DEL FILTRADO DIGITAL.	23
	• <i>Algoritmo de Fourier</i>	23
	• <i>Algoritmo Coseno</i>	25
	• <i>Algoritmo seno</i>	25
5.3	PREPROCESAMIENTO DE LA INFORMACIÓN.	26
5.3.1	<i>Metodología de escalamiento</i>	26
5.3.2	<i>Metodología de PCA (Análisis de Componentes Principales)</i>	26
5.3.3	<i>Metodología de ICA (Análisis de Componentes Independientes)</i>	26
5.4	RESULTADOS DE LAS SIMULACIONES REALIZADAS.	27
CAPITULO 6.....		29
EXTRACCION DE LAS CARACTERISTICAS.....		29
DEL SISTEMA ELECTRICO DE POTENCIA (SEP).....		29
6.1	SELECCIÓN DE LA HERRAMIENTA ADECUADA PARA MODELAR LOS CASOS.	29
6.2	SELECCIÓN Y CONSTRUCCIÓN DEL MODELO PARA REPRESENTAR EL SEP.....	29
6.3	METODOLOGÍA DE ENTRENAMIENTO Y VALIDACIÓN ADAPTATIVA.....	30
6.4	GENERACIÓN DE LAS MUESTRAS DE ENTRENAMIENTO, VALIDACIÓN Y CHEQUEO PARA EL MODELO MAIA.....	32
CAPITULO 7.....		34

MODELO ADAPTATIVO DE INTELIGENCIA ARTIFICIAL (MAIA).....	34
7.1 MODELO ANFIS.....	34
7.2 MODELOS DE REDES NEURONALES.	38
7.2.1 <i>Clasificador de retro-propagación (BP).....</i>	39
7.2.2 <i>Clasificador de mapeo característico (FM).</i>	39
7.2.3 <i>Clasificador de Función de Base radial (RBF).</i>	40
7.2.4 <i>Clasificador de cuantificación vectorial de aprendizaje (LVQ).</i>	41
7.3 MODELO DE RED NEURONAL BP CON REGULARIZACIÓN BAYESIANA.....	42
7.4 MODELO ART (TEORÍA DE RESONANCIA ADAPTATIVA).....	43
7.5 MODELO ART2 MEJORADO (REDUCCIÓN DE RADIOS Y REENTRENAMIENTO EN LÍNEA).....	46
7.5.1 <i>Metodología formal para reducción de radios.....</i>	46
7.5.2 <i>Metodología de reentrenamiento en línea.</i>	50
CAPITULO 8	53
ENTRENAMIENTO, VALIDACION Y CHEQUEO	53
DE LOS MODELOS ANALIZADOS.....	53
8.1 MODELO ANFIS.....	53
8.2 MODELOS DE REDES NEURONALES (FM, BP, LVQ, RBF).....	54
8.3 MODELO DE RED NEURONAL BP CON REGULARIZACIÓN BAYESIANA.....	56
8.4 MODELO ART (TEORÍA DE RESONANCIA ADAPTATIVA).....	58
8.5 CONCLUSIONES DEL ANÁLISIS REALIZADO.....	58
CAPITULO 9	59
SISTEMA BASADO EN CONOCIMIENTO.....	59
CAPITULO 10	61
CONCLUSIONES Y TRABAJO FUTURO	61
10.1 CONCLUSIONES.	61
10.2 TRABAJO FUTURO.	62
REFERENCIAS.....	63

INDICE DE FIGURAS

FIGURA 1. PROBLEMÁTICA DEL DIAGNÓSTICO AUTOMÁTICO DE FALLAS Y SUS TRES PROBLEMAS FUNDAMENTALES: DIAGNÓSTICO AUTOMÁTICO CON SOE Y SCADA, DIAGNÓSTICO AUTOMÁTICO CON REGISTROS DE OSCILOPERTURBOGRAFÍA Y DIAGNÓSTICO DE FALLAS INTEGRADO [MCARTHUR, 2004]	5
FIGURA 2. REGISTRO TÍPICO DE UNA PERTURBACIÓN Y EL RESPECTIVO DIAGNÓSTICO DE LA FALLA EXTRAÍDO DE LA INFORMACIÓN DE ESTE REGISTRO, [KEZUNOVICK, 2000].	6
FIGURA 3. DIAGRAMA CONCEPTUAL DEL PROCEDIMIENTO PARA DETERMINAR LOS TÓPICOS FUNDAMENTALES DEL DIAGNÓSTICO AUTOMÁTICO DE FALLAS.	7
FIGURA 4. DIAGRAMA ESQUEMÁTICO QUE ILUSTRAS LOS ESTADOS TÍPICOS QUE SE PRESENTAN EN UN REGISTRO DE OSCILOPERTURBOGRAFÍA DURANTE UNA PERTURBACIÓN EN EL SEP.	18
FIGURA 5. COMPORTAMIENTO DE LOS CUATRO FILTROS ANALÓGICOS COMPARADOS CON EL IDEAL.	22
FIGURA 6. MODELO SELECCIONADO PARA EL ANÁLISIS DE LAS COMPONENTES PRINCIPALES DE CUALQUIER SISTEMA ELÉCTRICO DE POTENCIA (SEP) DEL MUNDO.	30
FIGURA 7. METODOLOGÍA DE ENTRENAMIENTO Y VALIDACIÓN ADAPTATIVA (MEVA) PARA LA SIMULACIÓN DEL SISTEMA ELÉCTRICO DE POTENCIA MEDIANTE ATP Y MATLAB.	33
FIGURA 8. DIAGRAMA DEL ALGORITMO DE CLASIFICACIÓN Y DE LA ARQUITECTURA ANFIS UTILIZADA.	35
FIGURA 9. FUNCIÓN DE PERTENENCIA UTILIZADA PARA LA ENTRADA DE CORRIENTE DE FASE.	36
FIGURA 10. FUNCIÓN DE PERTENENCIA UTILIZADA PARA LA ENTRADA DE CORRIENTE DE SECUENCIA CERO.	36
FIGURA 11. ARQUITECTURA GENERAL UTILIZADA POR EL MODELO DE ENTRENAMIENTO DE RETRO-PROPAGACIÓN.	39
FIGURA 12. ARQUITECTURA GENERAL UTILIZADA POR EL MODELO DE KOHONEN DE SOMF.	40
FIGURA 13. ARQUITECTURA GENERAL UTILIZADA POR EL MODELO DE RBF.	41
FIGURA 14. ARQUITECTURA GENERAL UTILIZADA POR EL MODELO DE LVQ.	41
FIGURA 15. DIAGRAMA DEL ALGORITMO DE CLASIFICACIÓN Y DE LA ARQUITECTURA DE RED NEURONAL BR UTILIZADA.	43
FIGURA 16. APRENDIZAJE DE NN COMBINADO NO SUPERVISADO-SUPERVISADO [KEZUNOVIC Y VASILIC, 2004].	43
FIGURA 17. MAPEO DEL ESPACIO DE PATRONES EN REGIONES DE DECISIÓN DE CATEGORÍAS USANDO ENTRENAMIENTO NO SUPERVISADO/SUPERVISADO, FUZZYFICACIÓN Y DEFUZZYFICACIÓN.	45
FIGURA 18. COMPARACIÓN ENTRE EL MODELO ART1 Y EL MODELO ART2 (KEZUNOVIC Y VASILIC, 2004: [39]).	46
FIGURA 19. A LA IZQUIERDA DOS CLUSTERS HOMOGÉNEOS NO INTERSECADOS, A LA DERECHA DOS CLUSTERS HOMOGÉNEOS INTERSECADOS, SIN PATRONES EN ESTA REGIÓN.	49
FIGURA 20. DOS CLUSTERS HOMOGÉNEOS INTERSECADOS, CON PATRONES EN ESTA REGIÓN.	49

<i>FIGURA 21. SE APLICA REDUCCIÓN DE RADIOS AL CLUSTER IZQUIERDO Y SE DESCARTA EL DERECHO POR QUE NO ES POSIBLE HACERLO.</i>	<i>50</i>
<i>FIGURA 22. CLASIFICACIÓN ERRÓNEA.</i>	<i>51</i>
<i>FIGURA 23. SELECCIÓN DE LOS K CLÚSTERES VECINOS MÁS CERCANOS.</i>	<i>51</i>
<i>FIGURA 24. NUEVO CONJUNTO DE PATRONES PARA EL REENTRENAMIENTO</i>	<i>52</i>
<i>FIGURA 25. CONJUNTO DE CLÚSTERES RESULTANTES DESPUÉS DEL REENTRENAMIENTO EN LÍNEA.</i>	<i>52</i>
<i>FIGURA 26. EVOLUCIÓN DEL ENTRENAMIENTO PARA LA CLASIFICACIÓN DEL TIPO DE FALLA.</i>	<i>57</i>
<i>FIGURA 27. SALIDA DE LA RED VS. TARGETS PARA LA CLASIFICACIÓN DEL TIPO DE FALLA.</i>	<i>57</i>
<i>FIGURA 28. SISTEMA BASADO EN CONOCIMIENTO PARA MODELAR LOS ESTADOS DE UN REGISTRO.</i>	<i>60</i>

INDICE DE TABLAS

TABLA 1. PREPROCESAMIENTO APLICADO AL MODELO ART.	28
TABLA 2. PREPROCESAMIENTO APLICADO AL MODELO NEURONAL BP.	28
<i>TABLA 3. DEFINICIÓN DE LAS SALIDAS DE LAS ANFIS DE ACUERDO CON EL TIPO DE FALLA</i>	38

CAPITULO 1

INTRODUCCION

1.1 Introducción

Este trabajo de tesis presenta inicialmente en el capítulo 1 los aportes, la motivación y la exploración de la problemática del diagnóstico automático de fallas, y en capítulo 2 los antecedentes que se utilizan como punto de partida para su realización. Se lleva a cabo una revisión del estado del arte y la comunidad científica relacionada y se determinan las limitaciones y oportunidades de investigación en este tema. Se realiza una descripción de las ventajas y desventajas de los métodos que han sido utilizados por distintos autores para intentar dar solución a los tópicos relacionados con el diagnóstico de fallas.

Una de las falencias que se ha logrado identificar se relaciona con la debilidad de estos métodos para adaptarse a los cambios topológicos de una red de transmisión real. Se ha observado que las soluciones propuestas son, en general, válidas para ciertas condiciones específicas del sistema pero falta aún profundizar e investigar sobre la influencia que tiene en los resultados el variar las condiciones de la red.

Teniendo en cuenta lo anterior, en el capítulo 3 se define el alcance y el problema a resolver y se propone la elaboración de un modelo Adaptativo de Inteligencia Artificial (MAIA) para diagnosticar automáticamente fallas en Sistemas de Transporte de Energía a partir de registros de osciloperturbografía, que se adapte a los cambios topológicos que se presentan en un sistema de potencia real. Para ello, se plantean algunas hipótesis, se formulan las respectivas preguntas de investigación, se definen los objetivos para dar respuesta a las preguntas de investigación y se propone en el capítulo 4 una metodología de trabajo fraccionada en cinco fases para alcanzar los objetivos planteados. En la primera fase, descrita en el capítulo 5, se lleva a cabo un análisis de preparación de datos (filtrado analógico, filtrado digital y preprocesamiento de señal). En la segunda fase, descrita en el capítulo 6, se presenta una Metodología de Entrenamiento y Validación Adaptativa (MEVA) utilizada para generar los patrones de entrenamiento, validación y chequeo del Modelo MAIA. En la tercera fase, descrita en el capítulo 7, se presenta el análisis, diseño y construcción del Modelo Adaptativo de Inteligencia Artificial (MAIA). En la cuarta fase, descrita en el capítulo 8, se presentan los resultados del entrenamiento, validación y chequeo de los modelos analizados. En la quinta fase, descrita en el capítulo 9, se presenta el análisis, diseño y construcción de un Sistema Basado en Conocimiento (SBC) para la integración del diagnóstico automático de fallas en un único sistema MAIA-SBC. Finalmente, en el capítulo 10, se presentan las conclusiones generales de la investigación y se propone el direccionamiento para trabajo futuro.

1.2 Aportes.

Los aportes de esta tesis son de tipo metodológico, conceptual y aplicado. En lo metodológico se alcanzaron dos importantes logros: se desarrolló una propuesta novedosa para el entrenamiento, validación y chequeo de los modelos de IA (Metodología de Entrenamiento y Validación Adaptativa-MEVA) y se formuló y validó una metodología para la reducción de radios en el modelo ART2 propuesto por [Vasilic, 2004]. En lo referente a la metodología MEVA se destaca su capacidad para considerar escenarios amplios para la determinación sistemática de las condiciones críticas esperadas en un Sistema Eléctrico de Potencia real. La metodología propuesta es genérica, escalable y adaptativa a cualquier SEP del mundo. En cuanto a la metodología de reducción de radios se destacan los criterios utilizados basados en las cercanías de patrones para determinar el alcance de la reducción. En lo conceptual se propone una mejora al modelo ART2 (Teoría de Resonancia Adaptativa) investigado en la tesis de doctorado de [Vasilic, 2004] consistente en la incorporación del concepto novedoso de reentrenamiento en línea con lo cual el algoritmo puede aprender de las experiencias nuevas y mejorar su desempeño con el tiempo. En lo aplicado se propone un Sistema Basado en Conocimiento para determinar el diagnóstico automático de fallas inspirado en dos aspectos básicos que rigen el cerebro humano: el hardware o conocimiento conexionista de bajo nivel almacenado en redes neuronales y ART (modelo MAIA) y el software ó conocimiento de alto nivel incorporado en meta-reglas definidas por los expertos en análisis de fallas.

1.3 Difusión de resultados.

A continuación se listan las publicaciones que se han elaborado a raíz de los resultados obtenidos en la realización de esta tesis de maestría:

Internacional.

“Comparative Analysis between Models of Neural Networks for the classification of faults in Electrical Systems”. Congreso CERMA 2007. Este artículo se encuentra publicado en la IEEE. Location: Cuernavaca, Morelos, México. ISBN:978-0-7695-2974-5. 2007-10-29.

Nacionales.

“Algoritmo Neuro-Difuso para la Detección y Clasificación de fallas en líneas de transmisión usando ANFIS”. Este artículo se encuentra publicado en la revista Avances en Sistemas e Informática. 29-06-2007.

“Modelo Adaptativo de Inteligencia Artificial (MAIA) para el diagnóstico automático de fallas a partir de registros de osciloperturbografía”. Artículo en revisión para ser enviado a concursar para ser publicado en la revista DYNA.

“Metodologías de Preprocesamiento de registros de osciloperturbografía aplicado al entrenamiento, validación y chequeo de algoritmos de IA” (En revisión).

“Sistema Basado en Conocimiento para el diagnóstico de fallas a partir de registros de osciloperturbografía” (En revisión).

1.4 Motivación

Los Sistemas Eléctricos de Potencia se componen de una serie de equipos interconectados entre sí (generadores, líneas de transmisión, transformadores, entre otros) los cuales están continuamente expuestos a fallas. Cuando se presenta una falla en alguno de estos componentes los sistemas de protección deben actuar sobre los respectivos equipos de interrupción para aclarar la falla. Lo anterior produce un impacto sobre el sistema de potencia que debe ser analizado por los centros de control involucrados y definir las correspondientes pautas adecuadas para el restablecimiento.

Para detectar este tipo de eventualidad y realizar el análisis respectivo las empresas de electricidad disponen de diversas herramientas en tiempo real: SOE (Sequence of Events), SCADA (Supervisory Control Adquisition Data), DFR (Digital Fault Records) y otros.

Sin embargo, en el momento en que se presentan los eventos los ingenieros analistas de los centros de control se ven enfrentados a clasificar y analizar manualmente una gran cantidad de información lo cual dificulta la toma de decisiones en tiempo real.

Dependiendo de la magnitud del evento (por ejemplo, un apagón de una gran área eléctrica del país) la avalancha de información resultante se vuelve normalmente inmanejable y por este motivo la toma de decisiones para el restablecimiento pasa a ser influenciada mas por la experiencia de las personas que por la información misma. Lo anterior ha llevado en diversas ocasiones a reincidir nuevamente sobre componentes fallados con los consecuentes retardos en el restablecimiento del servicio y en algunos casos a producir daños permanentes sobre equipos.

Mediante el análisis postoperativo detallado de la información anterior se han logrado identificar muchas anomalías que se pudieron haber evitado. Es decir, situaciones que de haberse analizado ágilmente en tiempo real (por ejemplo automáticamente) y de manera inteligente (asistida por algoritmos de inteligencia artificial) se pudieron haber previsto y haber ayudado al operador del Centro de Control a tomar una mejor decisión. Esto demuestra, entonces, que para llevar a cabo un adecuado restablecimiento del sistema no es suficiente con la experiencia del operador y que se hace necesario apoyarlo con algún sistema inteligente, confiable y ágil que diagnostique automáticamente la causa de la falla con el fin de mejorar la toma de decisiones en tiempo real.

1.5 Exploración de la problemática.

La problemática del diagnóstico automático de fallas gira en torno de tres problemas fundamentales: el diagnóstico automático de fallas a partir de la información del SOE y el SCADA, el diagnóstico automático de fallas a partir de la información contenida en los registros de osciloperturbografía (señales analógicas de tensiones y corrientes) y el diagnóstico automático de fallas integrado (Inteligencia Artificial Distribuida: IAD) que resulta de la comparación inteligente de los dos diagnósticos anteriores.

En la **Figura 1** se ilustra en forma genérica una porción de un sistema de transmisión en el momento que se presenta una falla. La información del evento se captura en forma de señales digitales provenientes del sistema SOE y SCADA de las subestaciones involucradas con esta perturbación y de las señales analógicas provenientes desde los Registradores Digitales de Fallas (DFR). A partir de esta información se puede generar un diagnóstico automático de falla a partir de SOE y SCADA, un diagnóstico automático a partir de registros y un diagnóstico automático integrado (Inteligencia Artificial Distribuida: IAD).

La presente investigación se enfoca en el diagnóstico de fallas a partir de registros de osciloperturbografía. En la **Figura 1** se ilustra de manera genérica los módulos que serán el objeto de la propuesta de investigación de esta tesis, para obtener un diagnóstico automático de la falla a partir de los registros de osciloperturbografía. Como se observa, los registros capturados son pasados a una fase de preparación de los datos. Esta información procesada entra a un módulo denominado “Modelo Adaptativo de IA” - MAIA que se entrena, valida y chequea a través de la Metodología MEVA y posteriormente se integra en un Sistema Basado en Conocimiento (SBC) encargado de determinar el diagnóstico automático de la falla.

En la **Figura 2** se ilustra un registro típico capturado por un DFR durante una perturbación y el concepto de Diagnóstico Automático de Fallas. A partir del procesamiento de la información contenida en el registro, es posible determinar un diagnóstico de lo que se presentó en el sistema. En el caso mostrado, se observan resaltados, en color rojo, los tópicos fundamentales que deben ser determinados automáticamente mediante técnicas de IA.

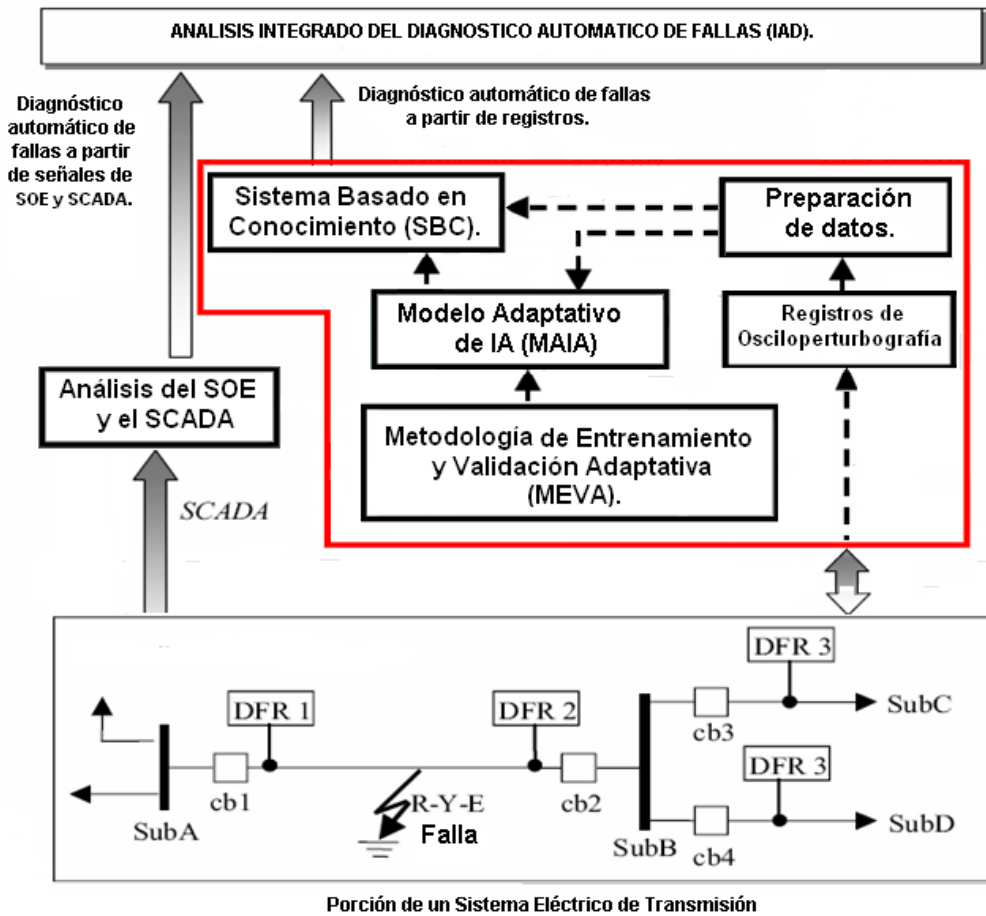
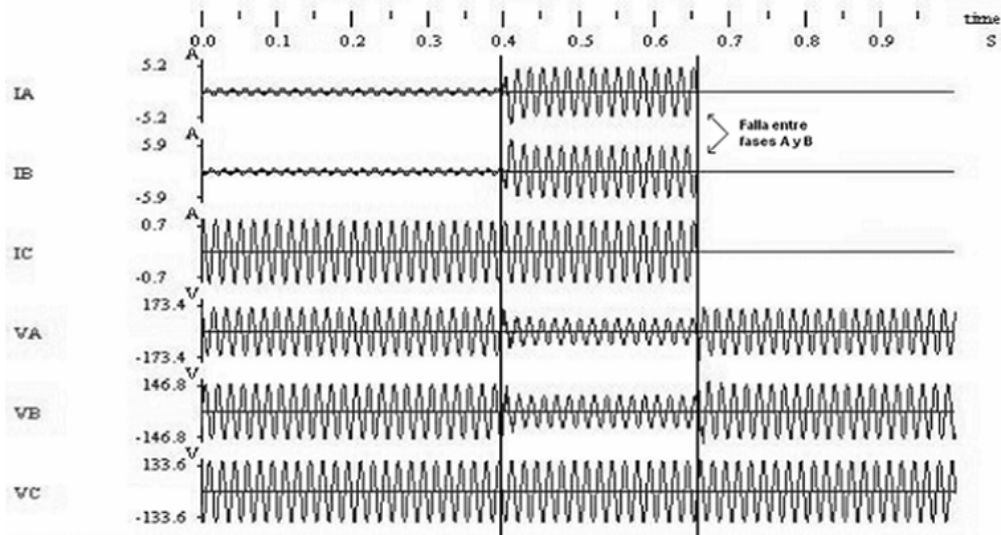


Figura 1. Problemática del Diagnóstico Automático de Fallas y sus tres problemas fundamentales: diagnóstico automático con SOE y SCADA, diagnóstico automático con Registros de osciloperturbografía y diagnóstico de fallas integrado [McArthur, 2004]

Una de las grandes dificultades al afrontar este diagnóstico está relacionada con el hecho de que ningún registro “nuevo” es igual a otro que haya ocurrido en el pasado. Es decir, que los modelos seleccionados deben ser capaces de generalizar y abstraer el conocimiento de manera tal que puedan responder apropiadamente ante los diversos tipos de registros que se presenten en la realidad.

El modelo Adaptativo de IA (MAIA) que se propone en este trabajo de investigación se concibe para recibir a la entrada archivos en formato IEEE COMTRADE (Common Format For Transient Data Exchange) correspondientes con los registros de osciloperturbografía capturados y a partir de esta información, diagnosticar lo que aconteció en el sistema independiente de la ubicación de las subestaciones involucradas, los cambios topológicos de la red y la variabilidad del despacho horario de carga.

Diagnóstico Automático de la Falla



Recierre bifásico no exitoso ante falla entre las fases A y B debido a descarga atmosférica. La falla se presentó hacia adelante y se localizó a 50 km desde la subestación asociada con el registro. La falla fue aclarada a los 260 ms después de iniciada la falla mediante el disparo trifásico del interruptor de esta bahía.

Figura 2. Registro típico de una perturbación y el respectivo diagnóstico de la falla extraído de la información de este registro, [Kzunovick,2000].

En la **Figura 3** se ilustra un diagrama conceptual del procedimiento para determinar los tópicos fundamentales del diagnóstico automático de fallas. Inicialmente los registros de osciloperturbografía ingresan a un módulo de preparación de datos que realiza las siguientes funciones: lee la información de los registros en el formato estandarizado COMTRADE, realiza el filtrado analógico y digital de las señales de tensiones y corrientes y preprocesa (normaliza) la información con el fin de facilitar el entrenamiento de los algoritmos de Inteligencia Artificial.

Posteriormente, la información ingresa al Modelo Adaptativo de Inteligencia Artificial (MAIA) que se encarga, mediante la utilización de técnicas de inteligencia artificial, de determinar los tópicos fundamentales del diagnóstico: detección de la falla, direccionalidad de la falla, la clasificación de la falla, identificación del componente fallado, la localización de la falla y la identificación de la causa de la falla. En la presente investigación el alcance cubre la detección de la falla, la direccionalidad de la falla y la clasificación de la falla. Los demás tópicos son parte de trabajos futuros los cuales se pueden desarrollar a partir de la metodología conceptual propuesta en esta tesis para el modelo MAIA.

Finalmente, el modelo MAIA se integra en un Sistema Basado en Conocimiento para determinar automáticamente el diagnóstico de fallas.

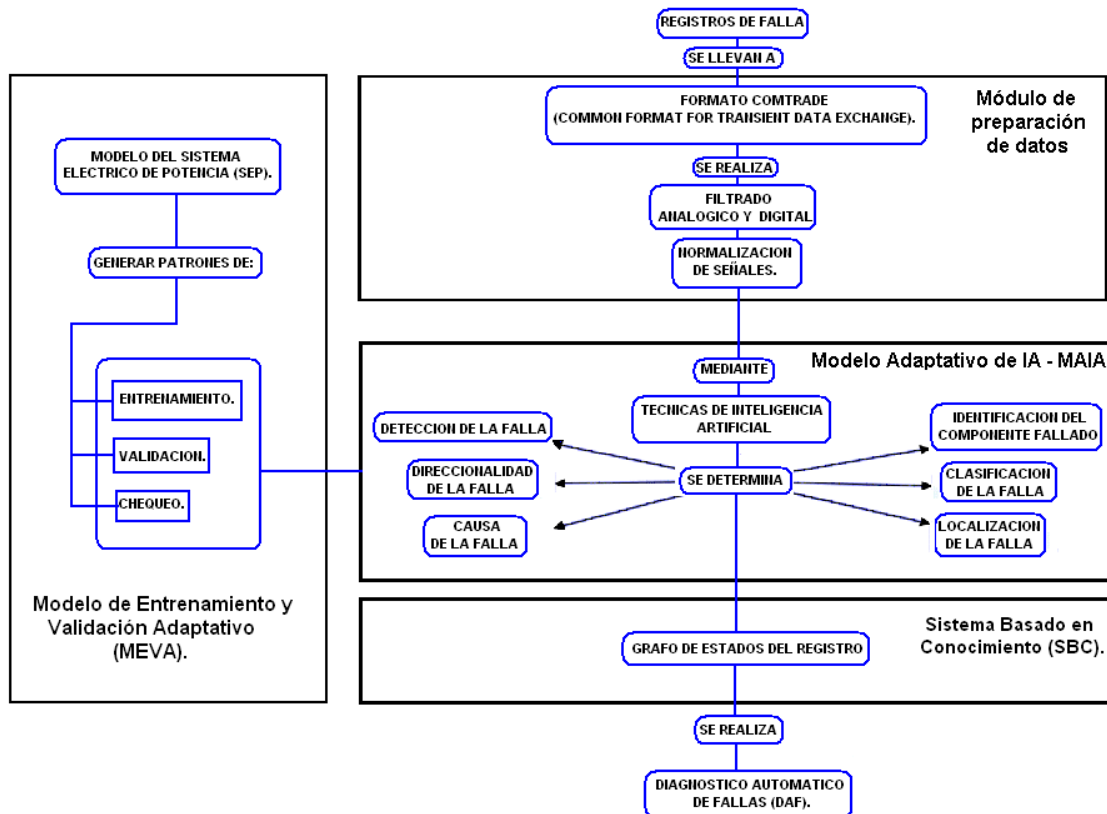


Figura 3. Diagrama conceptual del procedimiento para determinar los tópicos fundamentales del diagnóstico automático de fallas.

El presente trabajo de investigación consistió en desarrollar y validar un modelo Adaptativo de IA que se adaptara de manera inteligente a las diferentes condiciones eléctricas del sistema de potencia. Para lograr lo anterior, las técnicas de IA se seleccionaron robustas e inteligentes para adaptarse a las diversas condiciones eléctricas de una u otra subestación del sistema para generar automáticamente un diagnóstico apropiado de lo que sucedió durante la perturbación.

CAPITULO 2

ANTECEDENTES

2.1 Trabajos Previos.

2.1.1 Proyectos de Investigación y Desarrollo.

Desde hace aproximadamente 12 años, en ISA se ha venido trabajando en el desarrollo de competencias para el análisis y el diagnóstico de las fallas que se presentan en el Sistema de Transmisión Colombiano.

Dentro de todo este contexto se han logrado avances importantes en algunos proyectos de investigación y desarrollo los cuales se mencionan a continuación:

- **“Sistema de Información de la Gestión Operativa (SIGO)” [L.E Llano, 2000].**

Esta es una aplicación con la que se ha logrado elaborar una base de datos con información especializada asociada con el diagnóstico de fallas de todas las perturbaciones que se presentan en la red de ISA. Es decir, en la actualidad hay una minería de datos importante del sistema de transmisión Colombiano que se encuentra disponible para ser utilizada en diversos proyectos de investigación.

- **“Formulación plan piloto para diagnóstico automático de eventos”. [ISA-UNAL,2004].**

ISA presentó en Julio de 2004 un trabajo en el cual se obtuvo la formulación para el desarrollo de un sistema automático de análisis de eventos a nivel de subestación para la subestación Ancón Sur de ISA, basado en información de señales digitales de la RTU (Unidad Terminal Remota) y de los relés de protección SEL-321. En este trabajo se realizó la modelación del esquema de protección y se definieron reglas de diagnóstico para el análisis de los eventos mediante Redes de Petri Coloreadas. Este proyecto se desarrolló también con la participación de la Universidad Nacional de Colombia, sede Medellín.

- **“Herramientas informáticas para el diagnóstico automático de eventos en líneas de transmisión de energía eléctrica” [ISA-COLCIENCIAS-UNAL, 2005].**

Este proyecto se formuló ante COLCIENCIAS por parte de Interconexión Eléctrica S.A. E.S.P. como entidad beneficiaria y ejecutora y la Universidad Nacional de Colombia sede Medellín como entidad ejecutora. El proyecto ya fue aprobado por COLCIENCIAS y en la actualidad se encuentra en la fase final de su desarrollo.

Este proyecto pretende automatizar el proceso de diagnóstico automático de fallas en un sistema de transmisión de energía y comprende los siguientes objetivos específicos:

- ✓ Desarrollar un algoritmo que seleccione la información útil para el diagnóstico de eventos a partir de la información disponible de SOE, osciloperturbografía de voltajes y corrientes y reportes de los sistemas de protección.
- ✓ Elaborar un módulo de preprocesamiento que permita normalizar y estandarizar los formatos de las señales de SOE y del módulo de procesamiento de osciloperturbografías, de forma apropiada para ser utilizadas en la implementación de algoritmos para el diagnóstico de eventos.
- ✓ Desarrollar un módulo de procesamiento de señales digitales procedentes de SOE y relés de protección con el fin de realizar un diagnóstico durante el evento que permita evaluar el desempeño de los sistemas de protección, control y maniobra, identificar el activo afectado, caracterizar la naturaleza eléctrica del evento y determinar la secuencia del mismo.
- ✓ Desarrollar un módulo de procesamiento de señales de las osciloperturbografías de voltajes y corrientes, capaz de evaluar las características de las ondas sinusoidales, para completar y validar el diagnóstico del módulo digital y que además identifique el activo afectado (barra, línea o transformador) y determine la naturaleza eléctrica del evento (falla monofásica, bifásica o trifásica) y su localización geográfica por el método de impedancia, magnitudes y duración.
- ✓ Desarrollar un sistema de inteligencia artificial que recoja mediante reglas el conocimiento de los analistas de eventos y que mediante modelos represente el sistema de protecciones.

2.1.2 Trabajos Dirigidos de Grado.

Con relación a la temática específica del diagnóstico de fallas se han logrado desarrollar algunas tesis de pregrado en la Universidad Nacional sede Medellín:

- ✓ **Grisales, Jhon Faber y Gómez, Juan Camilo, (2003).** “Sistema de Diagnóstico de fallas para Sistemas de Transmisión de Energía utilizando redes de Petri”.

En este trabajo se presenta un enfoque de solución al problema de diagnóstico de fallas utilizando las redes de Petri. Es decir, mediante información digital proveniente desde el SOE y los relés de protección.

- ✓ **Molina, L. (2004).** “Preprocesamiento de señales analógicas para la caracterización de fallas en líneas de transmisión con algoritmos de inteligencia artificial”.

En este trabajo se presenta un primer acercamiento al procesamiento de las señales analógicas de los registros de osciloperturbografía y se plantean posibles metodologías de IA que se podrían utilizar para lograr caracterizar el tipo de falla y la identificación de la causa de la falla.

2.2 Estado del arte.

Con el fin de realizar la propuesta de investigación se llevó a cabo una búsqueda exhaustiva de bibliografía relacionada con el diagnóstico de fallas orientado al procesamiento de las señales analógicas de registros de osciloperturbografía.

En el Anexo A se analiza y se describe una lista de los principales artículos encontrados del estado del arte sobre el tema acorde con las temáticas requeridas por el diagnóstico de fallas tal como se ilustra en la **Figura 3**: Detección de la falla, direccionalidad de la falla, clasificación de la falla, localización de la falla y causa de la falla.

Para la detección de la falla se analizaron desde metodologías basadas en umbral [3], pasando por la utilización de técnica adaptativa difusa [4] y redes neuronales [5].

Para la direccionalidad de la falla se analizaron técnicas fundamentadas en redes neuronales [6,8 y 9] y mediciones fasoriales sincronizadas [7].

Para la clasificación de la falla se analizaron técnicas de teoría de resonancia adaptativa ART [10], conjuntos rugosos [11], redes neuronales [12,15 y 16], lógica difusa [13 y 18], redes neuro-difusas [14] y redes de mapeo característico [17].

Para la localización de la falla se analizaron técnicas de redes neuronales [19, 21 y 22] y redes autoorganizadas [20].

Para la causa de la falla [23] se analizó una metodología basada en regresión logística combinada con redes neuronales.

2.3 Comunidad Científica.

Principales investigadores del tema.

- **Sidhu**, T.S., Univ. of Western Ontario, London, Ont.
- **Oleskovicz**, M.: Universidade de Sao Paulo, Sao Carlos, Brazil.
- **Wang**, C., Sch. of Electrical Eng., Wuhan University, Wuhan 430072, China; Dispatch Ctr. Hubei, Wuhan 430077, China.

- **Kezunovic**, M., Department of Electrical Engineering, Texas A and M University, College Station, TX 77843-3128, United States.
- **Ferrero**, A., Dept. of Electr. Eng., Indian Inst. of Technol., Roorkee, India.
- **Mazon**, A.J., Dept. of Electr. Eng., Basque Country Univ.
- **Pradhan**, A.K., Department of Electrical Engineering, Indian Institute of Technology.
- **Schmaranz**, R., Institute for Electrical Power Systems, Graz University of Technology, 8010 Graz, Austria.
- **Aggarwal**, R.K., UK: Institute of Electrical Engineers. Dept. of Electron. & Electr. Eng., Bath Univ.
- **Johns**, A.T., UK: Institute of Electrical Engineers. Dept. of Electron. & Electr. Eng., Bath Univ.
- **Youssef**, O.A.S., Faculty of Industrial Education, Suez Canal University, Suez, Egypt.

2.4 Principales Revistas del tema.

- ✓ IEEE Transaction on Power Delivery.
<http://ieeexplore.ieee.org/Xplore/guesthome.jsp>
- ✓ IEEE Transaction on Power System.
- ✓ IEEE Computer Application on Power.
- ✓ IEEE Intelligent Systems.
- ✓ IEEE Transaction on Instrument Measurement.
- ✓ Electric Power Components and Systems.
- ✓ Electric Power Systems Research.
- ✓ Proceedings of IEE.

CAPITULO 3

ALCANCE Y DEFINICIÓN DEL PROBLEMA DE INVESTIGACIÓN

El alcance y la definición del problema de investigación se determinó con base en las limitaciones encontradas en el estado del arte del tema, los requerimientos de la operación del sistema eléctrico de potencia y consideraciones de tipo práctico.

3.1 Limitaciones encontradas en el estado del arte.

Del análisis realizado al estado del arte del tema se detectaron algunas falencias relacionadas con la debilidad de los métodos expuestos para adaptarse a los cambios topológicos de una red de transmisión real. En general, se observó que las soluciones propuestas son válidas para ciertas condiciones específicas del sistema pero falta aún profundizar e investigar sobre la influencia que tiene en los resultados el variar las características del Sistema Eléctrico de Potencia (SEP).

Las dificultades anteriores detectadas en la exploración del estado del arte motivó la presente investigación hacia la búsqueda de un Modelo Adaptativo de Inteligencia Artificial que considere las diversas condiciones críticas extremas esperadas en cualquier sistema eléctrico de potencia real del mundo y logre adaptarse a la variabilidad exigida por cualquier registro de falla nuevo de tal manera que proporcione un diagnóstico automático acertado aún en situaciones de alto nivel de dificultad.

3.2 Requerimientos del Sistema Eléctrico de Potencia.

Algunos de los aspectos más relevantes requeridos por la operación del sistema eléctrico en la actualidad son los siguientes:

- Hay un gran volumen de información durante los eventos que se presentan en un Sistema Eléctrico de Transmisión real debido a las altas tasas de muestreo de los datos.
- Se presenta pérdida de información debido a las conexiones incompletas en subestaciones.
- Esta información requiere ser analizada de una manera rápida, confiable y con valor agregado para la toma de decisiones en tiempo real.
- La labor de clasificación y procesamiento manual de esta información (tal como se hace en la actualidad), se vuelve muy engorrosa y sujeta a errores debido al estado de estrés del operador durante el restablecimiento del sistema eléctrico de potencia.

Para dar respuesta a este tipo de inconvenientes surgen alternativas como el diagnóstico automático de fallas para evaluar la información de una forma inteligente, confiable y ágil y apoyar al operador del Centro de Control en la toma de decisiones en tiempo real.

3.3 Consideraciones de tipo práctico.

Del análisis efectuado al estado del arte se pudo detectar que no todos los tópicos relacionados con el diagnóstico de fallas han sido considerados por los investigadores de este tema. Por ejemplo, la causa de la falla en los sistemas eléctricos de alta tensión es aún un tema sobre el que no hay mucha literatura disponible. En este caso particular solamente se pudo encontrar un artículo relacionado [Xu, 2006]. De otro lado, otros tópicos como la localización de la falla y la identificación del componente fallado son tan amplios que cada uno tiene material suficiente para ser investigados como tesis de maestría e incluso de doctorado (como es el caso de la localización de fallas).

Teniendo en cuenta lo anterior, se delimitó el alcance de la presente investigación a la detección de la falla, la direccionalidad de la falla y de manera especial a la clasificación de la falla.

3.4 Definición del problema de investigación.

Con base en el análisis anterior la presente investigación se orientó a analizar, diseñar, construir y validar un modelo Adaptativo de Inteligencia Artificial (MAIA) para diagnosticar automáticamente fallas a partir de registros de osciloperturbografía. Para lograr una alta confiabilidad en los resultados, este modelo se concibió para ser capaz de adaptarse a la variabilidad exigida por un sistema eléctrico de potencia real y tener la manera de aprender a partir de las experiencias nuevas que se le van presentando en el sistema eléctrico de potencia.

3.5 Hipótesis.

- Las características de falla de un sistema eléctrico de potencia se pueden clasificar en “clusters” eléctricamente similares.
- Esta agrupación se puede lograr a partir de resultados de casos de modelación del sistema de potencia (por ejemplo con ATP) o de registros reales de eventos ocurridos en el pasado.
- Una única técnica de IA no resuelve adecuadamente el problema por lo cual debe considerarse el modelamiento híbrido.

- Teniendo en cuenta lo anterior, es posible definir un Modelo ADAPTATIVO de IA (MAIA) que se adapte a los diversos cambios topológicos de un Sistema Eléctrico de Potencia real y con base en él producir un diagnóstico automático de fallas.

3.6 Preguntas de Investigación.

- ¿Cuáles técnicas de procesamiento de señal son apropiadas para procesar las señales analógicas de los registros de osciloperturbografía?
- ¿Cuáles técnicas de inteligencia artificial son apropiadas para el diagnóstico automático de fallas a partir de registros de osciloperturbografía y que se adapten a las diferentes condiciones de un Sistema Eléctrico de Potencia real?
- ¿Cómo validar las diferentes técnicas utilizadas de tal manera que se verifique su capacidad de adaptación a los cambios topológicos del sistema de potencia?

3.7 Objetivo general.

Proponer un Modelo Adaptativo de IA para diagnosticar automáticamente fallas en Sistemas de Transporte de Energía a partir de registros de osciloperturbografía.

3.8 Objetivos específicos.

- i. Seleccionar y caracterizar técnicas para el procesamiento de las señales analógicas de los registros de osciloperturbografía.
- ii. Seleccionar y caracterizar técnicas de IA para procesar señales analógicas de registradores de falla de tal forma que se adapten a los cambios topológicos de un Sistema Eléctrico de Potencia real.
- iii. Diseñar un Modelo ADAPTATIVO de IA (MAIA) que integre estas técnicas en una solución viable para lograr un diagnóstico automático de fallas a partir de registros de osciloperturbografía.
- iv. Construir un prototipo que valide el Modelo ADAPTATIVO propuesto.
- v. Entrenar, Validar y Chequear el prototipo a través de casos de estudio reales ó simulados.

CAPITULO 4

PROPUESTA METODOLOGICA

Con el fin de cumplir con los objetivos planteados, el trabajo de investigación se desarrolló en cinco fases acorde con el diagrama conceptual ilustrado en la **Figura 3**.

En la primera fase se prepararon los datos capturados de los registros de osciloperturbografía, en la segunda fase se extrajeron las componentes principales del sistema eléctrico de potencia, en la tercera fase se analizó, diseñó y construyó el Modelo Adaptativo de Inteligencia Artificial (MAIA), en la cuarta fase se entrenó, validó y chequeó el modelo MAIA.

Finalmente, en la quinta fase, el modelo MAIA se integró con un Sistema Basado en Conocimiento (SBC) para producir el diagnóstico automático de fallas y se validó todo este conjunto con casos simulados y registros reales de la red de ISA.

4.1 Fase 1: Preparar Datos.

En esta primera fase de preparación de datos, que le apunta al primer objetivo específico, los registros en formato COMTRADE [29] (IEEE Std C37.111-1999) provenientes de los registradores se procesaron de una manera adecuada de tal forma que pudieran ser utilizados por los algoritmos de IA en el modelo MAIA.

En esta fase se analizaron técnicas de procesamiento digital de señal (Fourier, Seno y Coseno) [30-35] para seleccionar el método que más se adaptara a los registros COMTRADE que se generan durante eventos reales de un sistema eléctrico de potencia.

Posteriormente, se realizó un análisis de sensibilidad a varias metodologías de preprocesamiento y normalización de señal con el fin de seleccionar la más adecuada para ser utilizada por los algoritmos de IA. Con base en la revisión bibliográfica sobre el tema se analizaron las siguientes metodologías: escalamiento de señales [10], [36-37], PCA (Análisis de Componentes Principales)[38] e ICA (Análisis de Componentes Independientes)[39-43].

4.2 Fase 2: Extraer las componentes principales del SEP.

En esta segunda fase, que le apunta al segundo objetivo específico, se elaboró un módulo de extracción de las características principales de un SEP para determinar el universo de entrada del problema y poder generalizar la variabilidad asociada con las condiciones eléctricas de un sistema de potencia durante eventos.

Para llevar a cabo la exploración exhaustiva de variabilidad de las condiciones eléctricas de un SEP se siguió el siguiente procedimiento:

- Selección de la herramienta adecuada para modelar los casos.
- Selección de los modelos apropiados para representar el SEP.
- Construcción del modelo del SEP.
- Análisis de sensibilidad de los casos y extracción de las componentes principales del SEP.
- Generación de los patrones de Entrenamiento, Validación y Chequeo para el modelo MAIA.

4.3 Fase 3: Analizar, Diseñar y Construir un prototipo del modelo MAIA.

En esta tercera fase se analizó, diseñó y construyó un prototipo del modelo MAIA para apuntarle al segundo, tercer y cuarto objetivos específicos.

Básicamente el modelo MAIA se concibió para recibir en su entrada las señales de tensiones y corrientes procesadas por el módulo de preparación de datos y luego mediante la utilización de técnicas de IA extraer el conocimiento necesario para resolver cualquier tópico del diagnóstico automático de fallas: Detección de la falla, Direccionalidad de la falla, Causa de la falla, Identificación del tramo fallado, Clasificación de la falla y Localización de la falla. Es decir, el modelo que se desarrolló es general y puede aplicarse de una manera similar a cada uno de estos tópicos. Dicho de otro modo, el modelo MAIA se concibió como una plantilla (objeto) que contiene unas características específicas que lo identifican de tal manera que cada tópico del diagnóstico de fallas pueda ser resuelto a partir de una instancia de este objeto.

Para lograr desarrollar un modelo adaptativo que soportara la variabilidad asociada con los registros de osciloperturbografía las técnicas de IA se seleccionaron de forma tal que cumplieran con los siguientes requerimientos básicos:

- Que tuvieran alta capacidad de generalización, es decir, que fueran robustas para soportar el aprendizaje de un número de muestras elevado (superior a 27500: valor estimado con la exploración sistemática de casos típicos esperados en cualquier SEP del mundo que se describe en la fase 2 de la metodología).
- Que fueran adecuadas para la clasificación de patrones ya que para resolver los tópicos relacionados con el diagnóstico automático de fallas se requería, en general, mapear salidas objetivo deseadas (targets) con las muestras de entrada (patrones de falla).

- Que facilitaran la adaptación de muestras nuevas al conjunto de muestras de entrenamiento y validación de tal forma que se posibilitara un aprendizaje continuo en el tiempo manteniendo a su vez una adecuada generalización.
- Una vez que fueron seleccionadas las técnicas apropiadas de IA se procedió a caracterizarlas acorde con los requerimientos específicos del tópico de diagnóstico de fallas que se estuviera considerando. Por ejemplo, cuando se analizó el tópico de clasificación de fallas se caracterizaron las entradas en valores rms-root mean square (tensiones de fase rms, corrientes de fase rms, corriente residual rms u otras) y las salidas de este modelo para lograr el diagnóstico deseado (detectar falla en la fase A, o falla bifásica a tierra u otra).
- Una vez caracterizadas las técnicas de IA a utilizar se procedió a diseñar el modelo MAIA. En esta etapa de diseño se consideraron las siguientes pautas generales:
 - Diseñar la estructura del modelo de tal forma que fuera flexible y adaptable a los cambios topológicos de un sistema eléctrico de potencia real. Para ello se adoptó una metodología basada en la extracción de características del modelo general del SEP combinada con la utilización de técnicas de IA (Modelo MAIA) para la clasificación apropiada del universo de entrada acorde con las necesidades específicas de cada uno de los tópicos del diagnóstico automático de fallas ilustrados en la *Figura 1*. De esta manera, se logró delimitar el universo de entrada del problema (ya que las muestras de entrada se obtuvieron de resultados concretos de casos simulados) manteniendo a su vez un alto grado de generalización (ya que se consideró una gran variedad de casos esperados en cualquier SEP del mundo bajo diversas circunstancias operativas).
 - Diseñar módulos de IA que pudieran acoplarse adecuadamente para lograr un estado objetivo deseado (acorde con los requerimientos del tópico de diagnóstico que se esté considerando).
 - Diseñar procedimientos iterativos que consideraran técnicas adaptativas, que permitieran mejorar la clasificación de las muestras de entrada nuevas (muestras diferentes a las de entrenamiento y validación) haciéndolas adaptativas a condiciones críticas de operación del SEP.
 - Diseñar estrategias de entrenamiento, validación y chequeo del modelo MAIA de tal manera que se lograra una reducción del error de clasificación comparado con el que se produce en otros modelos convencionales que no consideran la variabilidad de las condiciones del SEP.

Finalmente, una vez se definieron todas las anteriores consideraciones del diseño, se procedió a construir un prototipo del modelo MAIA, de tal manera que se cumpliera con estos requisitos establecidos. En esta etapa, se tuvieron en cuenta consideraciones tales como prevenir la redundancia ó la ejecución de pasos innecesarios que finalmente afectarían la eficiencia del modelo.

4.4 Fase 4: Entrenar, Validar y Chequear el prototipo del modelo MAIA.

Una vez finalizada la etapa de construcción, el prototipo del modelo MAIA se encontraba preparado para ser entrenado, validado y chequeado para lo cual se siguieron los lineamientos respectivos establecidos en la fase de diseño.

El objetivo fue lograr un error de clasificación aceptable para las diversas condiciones del SEP consideradas. Las actividades de esta fase le apuntaron al quinto objetivo específico.

4.5 Fase 5: Diseñar, Construir y Validar el Sistema Basado en Conocimiento (SBC).

Finalmente, se diseñó, construyó y validó un Sistema Basado en Conocimiento (SBC) para realizar la integración con el modelo MAIA y determinar el diagnóstico automático de fallas. En la **Figura 4** se ilustra la estructura fundamental en la que se soporta el SBC utilizando las transiciones de estados que se presentan en un registro de osciloperturbografía durante una perturbación en el SEP. Las actividades de esta fase le apuntaron al quinto objetivo específico.

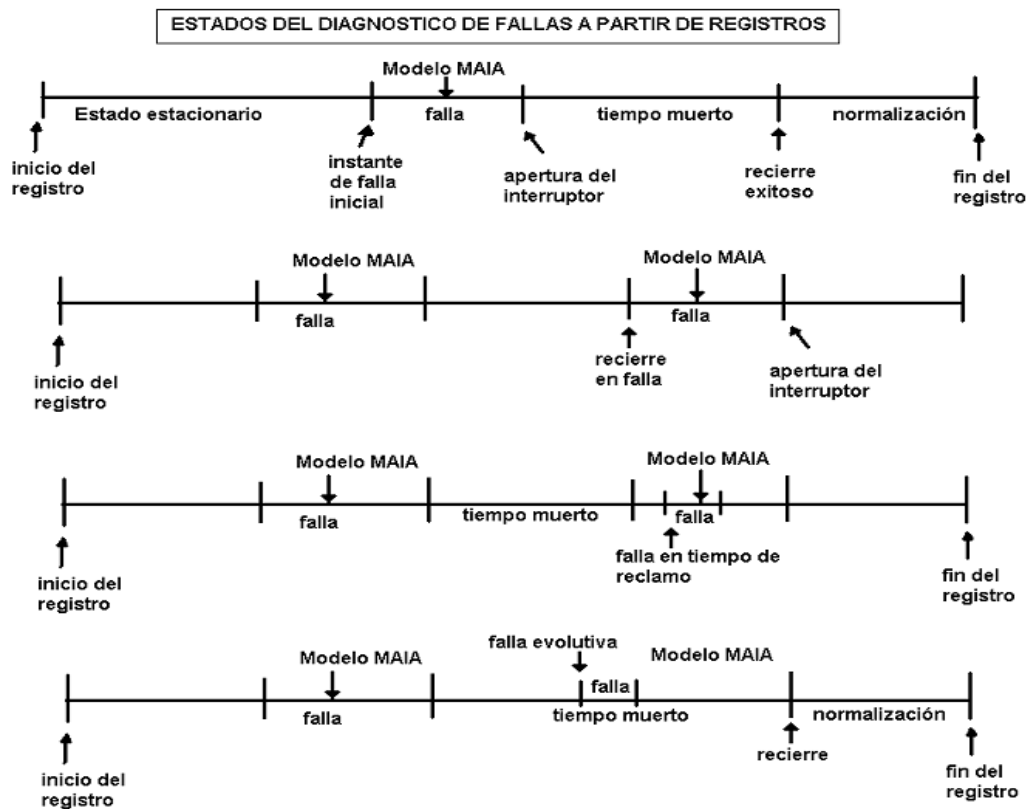


Figura 4. Diagrama esquemático que ilustra los estados típicos que se presentan en un registro de osciloperturbografía durante una perturbación en el SEP.

CAPITULO 5

PREPARACION DE LOS DATOS

En la preparación de datos se llevaron a cabo varias actividades: la selección técnica de filtrado analógico, la selección técnica del filtrado digital y el preprocesamiento de la información para ser utilizada por los algoritmos de IA.

5.1 Selección técnica del filtrado analógico.

Cuando una señal analógica es muestreada, en su espectro de frecuencias aparecen réplicas del espectro original para valores múltiplos de la frecuencia de muestreo. Si esta frecuencia es por lo menos el doble que la frecuencia fundamental de la señal, las réplicas no se traslapan y la señal puede ser reconstruida a partir de su espectro de frecuencia (Teorema de muestreo o Nyquist), eliminando las réplicas mediante un filtro pasabajos. Sin embargo, si la frecuencia de muestreo es menor que dos veces dicha frecuencia, las réplicas se traslapan y no es posible recuperar la señal original ya que su espectro se distorsiona originando el efecto de aliasing. Por este motivo, la entrada de muchos dispositivos de procesamiento digital de señales es un filtro analógico anti-aliasing, que limita el contenido de frecuencias de la señal de entrada a un intervalo que pueda manejar el filtro digital.

El filtro analógico se considera un dispositivo selectivo a la frecuencia que permite dar forma a la respuesta en magnitud o en fase. El diseño de éstos se basa principalmente en la aproximación de las especificaciones de magnitud o de fase mediante polinomios o funciones racionales, por lo general, en especificaciones de frecuencia (aristas de las bandas de paso y supresión) y en especificaciones de magnitud (atenuación máxima en la banda de paso y atenuación mínima en la banda de supresión) para generar la función de transferencia de fase mínima del filtro con el orden más pequeño que cumpla las especificaciones. Las especificaciones de magnitud de un filtro por lo general son dadas por la atenuación en la banda de paso y la atenuación en la banda de supresión o rechazo, expresadas en decibeles.

Los filtros clásicos aproximan el cuadrado de la función de magnitud $|H(v)|^2$ de un prototipo pasa-bajas por un polinomio o razón de polinomios en v^2 ; se obtiene una función de transferencia de fase mínima a partir de esta aproximación [30]. El cuadrado de la función de magnitud y la atenuación de un prototipo pasa-bajas de n -ésimo orden tienen la forma:

Ecuación 1
$$|H(v)|^2 = \frac{1}{1 + \alpha^2 L_n^2(v)} \quad A_{dB}(v) = 10 \log[1 + \alpha^2 L_n^2(v)] \text{ (dB)}$$

En estas expresiones, $L_n(v)$ es un polinomio o función racional de n-ésimo grado, y α controla el rizo en la banda de paso. La diferencia entre los distintos tipos de filtros clásicos se encuentra principalmente en la selección de $L_n^2(v)$, la cual se hace con la finalidad de satisfacer las especificaciones deseadas. Se necesita que $L_n^2(v) \approx 0$ en la banda de paso (para asegurar en ella una ganancia casi unitaria) y que $L_n^2(v) \gg 0$ en la banda de supresión (para asegurar que la ganancia en ella sea casi cero). La única ecuación de diseño que se necesita es la de atenuación. El orden del filtro n y el parámetro α se obtienen evaluando la relación de atenuación en los límites de la banda de paso y de supresión. Con esto se establece la forma exacta de $|H(v)|^2$, a partir de la cuál es fácil obtener la función de transferencia $H_p(s)$ del prototipo.

Para el filtrado anti-aliasing aplicado a un registro de osciloperturbografía se evaluaron cuatro tipos de filtros [30-35]: Butterworth, Chebyshev I, Chebyshev II y Elíptico.

- **Filtro Butterworth**

Es fundamentalmente plano debido a que la elección de $L_n(v) = v^n$ obliga a que todas sus derivadas sean cero en $v=0$, lo que garantiza no sólo la respuesta más plana en $v=0$ sino también la menor desviación con respecto a la ganancia unitaria en la banda de paso. Con esto se obtiene una respuesta en frecuencia monótona libre de sobretiros, pero a costa de una transición lenta de la banda de paso a la de supresión.

- **Filtro Chebyshev I.**

Se basa en un ajuste polinomial, pero en lugar de seleccionar los coeficientes (grados de libertad) del polinomio $L_n(v)$ para hacer la respuesta lo más plana posible sólo en el origen, como en el caso del Butterworth, lo que se desea es que la respuesta sea uniformemente buena para asegurar una concordancia exacta en varias frecuencias distribuidas en la banda de paso. Un concepto importante es el de los Polinomios de Chebyshev de n-ésimo grado que están descritos por la siguiente relación:

Ecuación 2 $T_n(x) = \cos(n \cos^{-1} x)$

El filtro Chebyshev de n-ésimo orden está descrito por:

Ecuación 3 $|H(v)|^2 = \frac{1}{1 + \varepsilon^2 T_n^2(v)} \quad A_{dB}(v) = 10 \log[1 + \varepsilon^2 T_n^2(v)] \text{ (dB)}$

ε es una medida del rizo en la banda de paso. La magnitud de los máximos y mínimos en la banda de paso depende únicamente de ε^2 , pero un orden n mayor dará como resultado más máximos y mínimos, y por consiguiente, una transición más pronunciada debido al polinomio de mayor orden. Es importante analizar el orden del filtro porque dependiendo si es par o impar varía su respuesta.

El filtro de Chebyshev proporciona una atenuación adicional de $6(n-1)$ dB en la banda de supresión si se le compara con el filtro Butterworth, lo que da como resultado una transición mucho más pronunciada para un filtro del mismo orden. Sin embargo, ésta mejora se obtiene a costa de la introducción de rizados en la banda de paso.

- **Filtro Chebyshev II.**

También llamado Chebyshev inverso. Surge de la necesidad de desarrollar una característica en magnitud del filtro con una transición pronunciada como la del filtro de Chebyshev, y una respuesta en fase con buenas propiedades en lo que respecta al retraso de propagación que sean similares a las de un filtro Butterworth. Es decir, se busca una respuesta en magnitud que sea lo más plana posible en la banda de paso, con la finalidad de mejorar el desempeño en lo que respecta al retraso, y que retenga algo del comportamiento de igual rizo con la finalidad de asegurar una transición pronunciada.

Este filtro está descrito por:

Ecuación 4 $|H(v)|^2 = \frac{\mu^2 T_n^2(1/v)}{1 + \mu^2 T_n^2(v)}$

Una característica importante es que la ganancia en DC (o pico) $|H(0)|$ siempre es 1, cualquiera que sea el orden del filtro.

- **Filtro elíptico**

Proporciona rizos en las dos bandas mediante el empleo de funciones racionales cuyo numerador y denominador exhiben la propiedad de igual rizo. El cuadrado de la función de magnitud de esta aproximación puede describirse con la expresión:

Ecuación 5

$$|H(v)|^2 = \frac{1}{1 + L_n^2(v)} = \frac{1}{1 + \varepsilon^2 R_n^2(v, \delta)}$$

$R_n(v, \delta)$ es la función racional de Chebyshev, ε^2 describe el rizo en la banda de paso y el parámetro adicional δ proporciona una medida de la magnitud del rizo en la banda de supresión.

Para analizar la respuesta en frecuencia de los filtros anteriores se pueden utilizar gráficas que permiten comparar el comportamiento de los diferentes tipos de filtro con el del filtro pasabajas ideal. Estas gráficas se obtienen mediante codificación en MATLAB.




Figura 5. Comportamiento de los cuatro filtros análogos comparados con el ideal.

En la **Figura 5** se puede analizar el comportamiento de los cuatro tipos de filtros de segundo orden y frecuencia de corte de 200 Hz, 1256.64 rad/seg. Se observa el carácter monotónico de la respuesta a la frecuencia del filtro Butterworth en sus bandas de paso y de rechazo, por lo que se maximiza la exactitud en una de las bandas con un error de aproximación en la otra. Los Chebyshev distribuyen la exactitud de manera uniforme en ambas bandas mediante una característica con

rizado (el Chebyshev I en la banda de paso y el Chebyshev II en la banda de rechazo). El elíptico distribuye el error de diseño uniformemente en ambas bandas mediante una característica de rizado en ambas.

Mediante simulaciones adicionales se puede analizar el efecto de variar el orden y la frecuencia de corte.

De este análisis se puede determinar que a medida que aumenta el orden del filtro aumentan también los sobreimpulsos y el tiempo de respuesta. La disminución de la frecuencia de corte produce un aumento considerable en el tiempo de respuesta.

Mediante las simulaciones realizadas se pudo determinar que el filtro Butterworth de segundo orden y frecuencia de corte 360 Hz es el más adecuado ya que presenta las menores oscilaciones y sobreimpulsos lo que implica un menor tiempo de retardo en la respuesta final del filtro.

Estos resultados de la evaluación anterior se encuentran acorde con la selección de filtros analógicos en aplicaciones similares [12] y [22] donde se ha utilizado con éxito filtros del tipo Butterworth para el filtrado del antialiasing.

5.2 Selección técnica del Filtrado Digital.

Se consideraron en esta evaluación tres de los algoritmos más utilizados en las protecciones distancia: Fourier, Coseno y Seno [30]. Las características de estos filtros están dadas en función de la cantidad de coeficientes y de los valores asignados a dichos coeficientes. La diferencia entre ellos radica en la forma como calculan dichos coeficientes.

- **Algoritmo de Fourier**

La obtención de los coeficientes del filtro se basa en el análisis en frecuencia de la señal $x[n]$ correspondiente a la señal muestreada de voltaje y corriente. Esta señal $x[n]$ se puede reconstruir por medio de su correspondiente transformada discreta de Fourier inversa (IDFT):

$$\text{Ecuación 6} \quad x(n) = \frac{1}{N} \sum_{k=0}^{N-1} X(k) e^{j2\pi kn/N}, \quad n = 0, 1, \dots, N-1$$

En la cual los valores de $X(k)$ estarán dados por la transformada discreta de Fourier (DFT):

$$\text{Ecuación 7} \quad X(k) = \sum_{n=0}^{N-1} x(n) e^{-j2\pi kn/N}, \quad n = 0, 1, \dots, N-1$$

Mediante una expansión de la ecuación (11), agrupando términos y teniendo en cuenta que las señales muestreadas son reales se llega a la siguiente ecuación:

$$\text{Ecuación 8} \quad x(n) = \frac{1}{N} \left[X(0) + 2|X(1)| \cos\left(\frac{2\pi n}{N} + \delta_1\right) + 2|X(2)| \cos\left(\frac{2\pi 2n}{N} + \delta_2\right) + \dots \right], \quad n = 0, 1, 2, \dots, N-1$$

Donde $\delta_1, \delta_2, \dots$ son los ángulos de $X(1), X(2), \dots$, respectivamente.

Dos parámetros que influyen en la respuesta del filtro es la longitud de la ventana y la frecuencia de muestreo (o el número de muestras por ciclo que es función de la frecuencia de muestreo y de la frecuencia fundamental). La longitud de la ventana es un factor importante dado que la aplicación de estos filtros es para protecciones distancia cuyo cálculo de la impedancia proporcional a la distancia eléctrica se realiza por lo general en tiempos que oscilan alrededor de un ciclo de la frecuencia fundamental después de producida la falla, por lo tanto se debe elegir los ciclos de acuerdo a estos requerimientos. La frecuencia de muestreo influye en la resolución del algoritmo, a medida que ésta se incrementa los algoritmos de filtrado permiten discriminar frecuencias de orden más elevado y de ésta manera bajar los requerimientos del filtro anti-aliasing.

El término que reconstruye la componente de frecuencia fundamental de la señal $x[n]$, con una ventana de un ciclo y un número de muestras dado por N_c , es:

$$\text{Ecuación 9} \quad x_o(n) = \frac{2|X(1)|}{N_c} \cos\left(\frac{2\pi F_o n}{F_s} + \delta_1\right) \quad n = 0, 1, 2, \dots, N_c - 1$$

Como el objetivo es obtener el fasor (magnitud y ángulo) de la componente fundamental presente en la señal $x[n]$, las ecuaciones que dan las componentes del fasor y de las cuales se pueden extraer los coeficientes del filtro son:

$$\text{Ecuación 10} \quad x_{or} = \frac{2}{N_c} \sum_{n=0}^{N_c-1} x(n) \cos\left(\frac{2\pi n}{N_c}\right) \quad x_{oi} = -\frac{2}{N_c} \sum_{n=0}^{N_c-1} x(n) \sin\left(\frac{2\pi n}{N_c}\right)$$

x_{or} Representa el valor pico de la componente real del fasor de frecuencia fundamental de la señal $x(n)$.

x_{oi} Representa el valor pico de la componente imaginaria del fasor de frecuencia fundamental de la señal $x(n)$.

La representación en forma polar del fasor correspondiente es:

$$\text{Ecuación 11} \quad |x_o| = \sqrt{(x_{or})^2 + (x_{oi})^2} \quad \varphi_o = \tan^{-1} \left(\frac{x_{oi}}{x_{or}} \right)$$

- **Algoritmo Coseno**

En el de Fourier las componentes del fasor de frecuencia fundamental se obtienen mediante la combinación de un filtrado Coseno y uno Seno. Para un filtro Coseno, el módulo y el ángulo del fasor de frecuencia fundamental correspondiente a la señal de entrada $x[n]$ se obtiene así:

$$\text{Ecuación 12} \quad |x_o| = \sqrt{\left[x_{or}^{(t)} \right]^2 + \left[x_{or}^{(t-N_c/4)} \right]^2} \quad \varphi_0 = \tan^{-1} \left[\frac{x_{or}^{(t-N_c/4)}}{x_{or}^{(t)}} \right]$$

Los coeficientes de este filtro están dados entonces por:

$$\text{Coeficientes del filtro coseno: } \cos \left[\frac{2\pi}{N_c} n \right]$$

- **Algoritmo seno.**

Para un filtro Seno, el módulo y el ángulo del fasor de frecuencia fundamental correspondiente a la señal de entrada $x[n]$ se obtiene así:

$$\text{Ecuación 13} \quad |x_o| = \sqrt{\left[x_{oi}^{(t)} \right]^2 + \left[x_{oi}^{(t-N_c/4)} \right]^2} \quad \varphi_0 = \tan^{-1} \left[\frac{x_{oi}^{(t-N_c/4)}}{x_{oi}^{(t)}} \right]$$

Con base en la evaluación realizada a los tres filtros anteriores, se seleccionó el filtro de Fourier como el más apropiado para determinar las componentes de 60 Hz debido a que utiliza un ciclo completo para muestreo y por lo tanto es más preciso. En aplicaciones ON-line como es el caso del procesamiento de señal en los relés digitales, los fabricantes sacan provecho del muestreo de medio ciclo para propósitos de aumentar velocidad de respuesta. En aplicaciones OFF-line, sin embargo, como es el caso del procesamiento de registros de osciloperturbografía la velocidad no es el factor preponderante y en cambio sí resulta más importante la precisión en el cálculo.

5.3 Preprocesamiento de la información.

Con el fin de seleccionar una técnica adecuada para la normalización de la señal de entrada a los algoritmos de IA se realizaron pruebas de preprocesamiento de varios registros de osciloperturbografía utilizando las siguientes metodologías: escalamiento de señales, PCA (Análisis de Componentes Principales e ICA (Análisis de Componentes Independientes).

5.3.1 Metodología de escalamiento.

La metodología del escalamiento ha sido utilizado por diversos investigadores [10] y [36-37] para el preprocesamiento de señales analógicas de registros de osciloperturbografía. Este método, consiste fundamentalmente en escalar los valores de los patrones de entrada de tal manera que sean comparativamente similares. En el presente caso de estudio se adoptó un factor de escala de 1000 para los valores de corriente y de $230000/\sqrt{3}$ para los valores de voltajes.

5.3.2 Metodología de PCA (Análisis de Componentes Principales).

La metodología de PCA (Análisis de Componentes Principales) usa el método estadístico de SVD (Descomposición del valor Singular) para calcular las componentes principales [38]. Los vectores de entrada son multiplicados por una matriz cuyas filas consisten de los valores propios de la matriz de covarianza. Esto produce vectores de entrada transformados cuyas componentes son no correlacionadas y son ordenados de acuerdo a la magnitud de su varianza. Aquellos componentes que contribuyan solamente en una pequeña cantidad a la varianza total en el conjunto de datos son eliminados. De esta manera, en diversos casos se obtiene una reducción de la dimensionalidad de los vectores de entrada lo cual en algunas aplicaciones facilita el aprendizaje de los algoritmos de IA. Esta metodología asume que el conjunto de datos de entrada se encuentran previamente normalizados de tal manera que tengan media cero y desviación estándar igual a 1. Mediante la metodología de PCA se logra la proyección de los datos de entrada sobre ejes ortogonales orientados mediante las componentes principales obtenidas.

Para realizar el preprocesamiento mediante PCA se utilizaron las funciones `prestd` de MATLAB para la normalización inicial de los datos (media cero y desviación estándar igual a 1) y `prepca` para determinar la matriz de componentes principales.

5.3.3 Metodología de ICA (Análisis de Componentes Independientes).

El análisis de componentes independientes es un método estadístico que juega un papel importante en muchas aplicaciones tales como comunicaciones, extracción de características, análisis de señales biomédicas, y análisis de datos que involucren múltiples sensores. La tarea de ICA es extraer componentes

independientes estadísticamente a partir de sus mezclas lineales sin recurrir a ningún conocimiento previo. Es conocido que ICA [39] produce separación de fuente ciega. En otras palabras, puede recuperar fuentes ciegas a partir de sus mezclas lineales instantáneas por medio de una transformación lineal que transforma señales sensoriales a señales de salida que son estadísticamente independientes. El sistema desmezclado puede ser visto como un modelo de reconocimiento en el contexto de aprendizaje de máquina.

En MATLAB se dispone de una herramienta denominada ICALAB con la cual se puede acceder a diversos algoritmos relacionados con ICA los cuales ya se encuentran implementados y debidamente verificados por muchos investigadores en este campo.

Este programa ha sido diseñado y desarrollado por Andrzej Cichocki, Shun-ichi Amari, Krzysztof Siwek, Toshihisa Tanaka, Sergio Cruces, Pando Georgiev, Zbigniew Leonowicz, Tomasz Rutkowski, Seungjin Choi, Adel Belouchrani, Allan Barros, Ruck Thawonmas, Tetsuya Hoya, Wakako Hashimoto, Yasushi Terazono y Tomomi Watanabe en cooperación con otros miembros del laboratorio para procesamiento avanzado de señales del cerebro.

El programa ICALAB dispone de una GUI desde la cual se pueden cargar los datos a procesar. Dispone además de la posibilidad de seleccionar el tipo de algoritmo a utilizar y visualización de diversas características de interés con las cuales se optimiza el procesamiento de los datos acorde con las necesidades del problema a resolver.

Para el presente caso, se cargaron los datos a procesar desde un archivo de extensión *.mat de MATLAB y se verificaron los 19 algoritmos de ICA disponibles utilizando como criterio de selección los menores valores de desempeño de ortogonalidad e índice de desempeño de separabilidad.

5.4 Resultados de las simulaciones realizadas.

En el Anexo B se presentan los resultados de las diversas simulaciones realizadas. Con base en la exploración del estado del arte se consideraron los métodos de escalamiento, PCA e ICA aplicados a dos modelos: Teoría de Resonancia Adaptativa y Red Neuronal BP. En la Tabla 1 se resume el error porcentual encontrado para el modelo ART y en la Tabla 2 para la red neuronal BP utilizada para este estudio. Para la prueba de ambos modelos se consideraron 2214 patrones para entrenamiento, 558 patrones de validación y 558 patrones de chequeo.

Los resultados de esta evaluación permitieron concluir que para el caso específico de preprocesamiento de registros de osciloperturbografía el mejor método a adoptar es el de escalamiento de señales.

Tabla 1. Preprocesamiento aplicado al modelo ART.

	Escalados	PCA	ICA
Correctamente	936	322	939
Incorrectamente	180	794	177
Error	16%	71%	15%

Tabla 2. Preprocesamiento aplicado al modelo neuronal BP.

	Error de Entrenamiento (%)	Error de Validación (%)	Error de Chequeo (%)
Escalamiento de Señales	0.5872	4.8387	5.3763
PCA	95.2123	99.1039	98.9247
ICA	7.7236	14.3369	19.3548

CAPITULO 6

EXTRACCION DE LAS CARACTERISTICAS DEL SISTEMA ELECTRICO DE POTENCIA (SEP).

Con el fin de extraer las características del Sistema Eléctrico de Potencia se llevó a cabo la selección de la herramienta de modelación, la construcción del modelo del SEP y una Metodología de Entrenamiento y Validación Adaptativa (MEVA) para generar los patrones de entrenamiento, validación y chequeo del Modelo MAIA.

6.1 Selección de la herramienta adecuada para modelar los casos.

Para la realización de la exploración exhaustiva de la variabilidad de las condiciones eléctricas de un SEP se seleccionó como herramienta de simulación al programa ATP (Alternative Transient Program) la cual es reconocida a nivel mundial como una de las herramientas mas poderosas para el análisis de transitorios electromagnéticos ([44] y [45]).

6.2 Selección y construcción del modelo para representar el SEP.

Teniendo en cuenta que los valores de tensiones y corrientes resultantes en los dos extremos de una línea de transmisión se encuentran directamente relacionados con los valores de las impedancias fuente de ambos extremos, las corrientes y tensiones existentes en estado estacionario previo a la falla, la longitud de la línea de transmisión, la localización de la falla y el valor de las impedancias de falla acorde con el tipo de falla que se presente, se diseñó un modelo en ATP que permitiera representar este comportamiento genérico de condiciones esperadas y que a su vez pudiese ser extendible a cualquier SEP del mundo.

Para lograr esta finalidad se seleccionó el circuito eléctrico ilustrado en la **Figura 6**. Como se observa, consta básicamente de dos fuentes con sus respectivos equivalentes de Thèvenin que representan los aportes de cortocircuito, una línea de transmisión típica y resistencias para representar las impedancias de falla de cada una de las fases.

Con este modelo se logró reproducir las formas de ondas de tensiones y corrientes resultantes en los dos extremos de una línea de transmisión para un número exhaustivo de condiciones eléctricas esperadas en cualquier SEP del mundo y se pudo establecer un conjunto representativo de muestras del universo de fallas que se pueden producir en cualquier SEP y con ello delimitar el dominio de entrada del problema de diagnóstico de fallas a partir de registros de osciloperturbografía.




Figura 6. Modelo seleccionado para el análisis de las componentes principales de cualquier Sistema Eléctrico de Potencia (SEP) del mundo.

6.3 Metodología de Entrenamiento y Validación Adaptativa.

Con el fin de generar los patrones de entrenamiento, validación y chequeo del modelo MAIA acorde con la variabilidad esperada de condiciones eléctricas de cualquier SEP real del mundo se diseñó y construyó una Metodología de Entrenamiento y Validación Adaptativa (MEVA).

El método consiste en realizar una exploración exhaustiva de una diversidad de fallas simuladas en ATP que permita recorrer un conjunto representativo de condiciones eléctricas esperadas en cualquier SEP del mundo. Para ello, se llevó a cabo la siguiente exploración sistemática de posibilidades:

- **Variabilidad del valor de la impedancia fuente tanto del extremo emisor como del extremo receptor.**

En este punto, se consideraron 10 condiciones de impedancia fuente con diferentes grados de fortaleza y aterrizamiento cubriendo condiciones extremas entre un nivel de corto cercano los 50 kA y un nivel de cortocircuito inferior a 1 kA.

- **Variabilidad de las condiciones de carga de una línea de transmisión en estado estacionario.**

La variabilidad de las condiciones de carga de una línea de transmisión se encuentra relacionada con la diferencia angular entre el ángulo de carga del extremo emisor y el ángulo de carga del extremo receptor. Para variaciones angulares positivas el flujo de potencia resultante va desde el extremo emisor hacia el extremo receptor (exportación) y para las variaciones angulares negativas desde el extremo receptor al extremo emisor (importación).

Para este caso se estudio se consideró una condición de carga promedio de las líneas de transmisión de ISA correspondiente con un ángulo de 20 grados entre fuentes. Otras condiciones de carga tanto simuladas como de registros reales de ISA son consideradas en la fase de validación.

- **Variabilidad de la longitud de las líneas de transmisión.**

Para el presente caso de estudio se consideró una longitud de línea típica de 100 km que representa un valor central (entre 5 y 200 km) de las líneas de transmisión de ISA. El efecto de otras longitudes de línea tanto simuladas como de registros reales de ISA son consideradas en la fase de validación.

- **Variabilidad de la localización de la falla.**

Se consideraron seis tipos de ubicación de la falla de acuerdo con el grado de cercanía al extremo emisor: Muy cercanas (por debajo del 10% de la longitud de la línea), Cercanas (entre el 10% y el 30% de la línea), Medianamente cercanas (entre el 30% y el 50% de la línea), Medianamente lejanas (entre el 50% y el 70% de la línea), Lejanas (fallas ubicadas entre el 70% y el 90% de la longitud de la línea) y Muy lejanas (fallas ubicadas mas allá del 90% de la longitud de la línea).

- **Variabilidad de la impedancia de la falla.**

Se consideraron seis tipos de valores para representar la impedancia de falla: muy baja impedancia (inferior a 1 ohm), baja impedancia (entre 1 y 20 ohm), impedancia medio-baja (entre 20 y 40 ohm), impedancia medio-alta (entre 40 ohmios y los 60 ohmios), alta impedancia (entre 60 y 90 ohmios) y muy alta impedancia (superior a los 90 ohm).

- **Variabilidad del tipo de falla.**

Se consideraron los tipos de falla típicos en los sistemas de transmisión del mundo: Falla monofásica (A,B,C), Falla bifásica aislada (AB, BC y CA), Falla bifásica a tierra (AB-g, BC-g, CA-g) y Falla trifásica (ABC).

6.4 Generación de las muestras de Entrenamiento, Validación y Chequeo para el modelo MAIA.

Con el fin de generar automáticamente la variabilidad de las condiciones esperadas en un SEP real se integró la metodología MEVA dentro de un módulo en MATLAB tal como se ilustra en la **Figura 7**. Como se observa se parte de un sistema eléctrico base modelado en ATP (como el ilustrado en la **Figura 6** y bosquejado en color amarillo en la **Figura 7**); posteriormente, mediante MATLAB en un módulo denominado ajuste de escenarios se considera el análisis de sensibilidad propuesto por la metodología MEVA y se genera un archivo en formato ATP (bosquejado en color magenta en la **Figura 7**) que contiene la información de entrada para realizar las simulaciones en el programa ATP y un archivo con características del SEP que contiene información sobre el tipo de falla, las impedancias fuente, la impedancia de falla y la localización de la falla. A continuación, mediante el programa ATP se corren los casos de falla considerados y se genera un archivo de resultados de las fallas simuladas. Los resultados obtenidos son procesados luego mediante MATLAB para generar los patrones de Entrenamiento, Validación y Chequeo del modelo MAIA. En la **Figura 7** se ilustra esquemáticamente todo el flujo de información desde las simulaciones con ATP y MATLAB hasta llegar al Módulo Adaptativo de IA (MAIA).

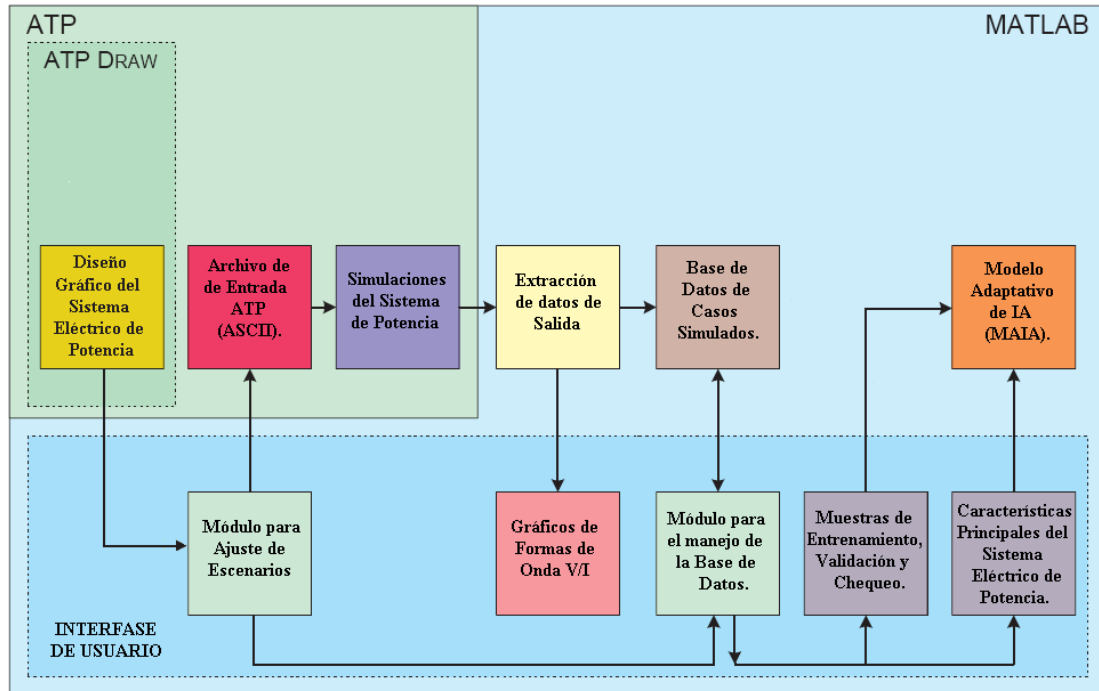


Figura 7. Metodología de Entrenamiento y Validación Adaptativa (MEVA) para la simulación del Sistema Eléctrico de Potencia mediante ATP y MATLAB.

En el análisis de sensibilidad anterior se generaron 46996 casos de los cuales 36500 se utilizaron para el entrenamiento y 10496 para la validación y el chequeo. Estos casos de validación y chequeo se simularon como condiciones intermedias de los patrones de entrenamiento con el fin de verificar que no hubiera sobreentrenamiento (etapa de validación) y que el modelo tuviera una adecuada capacidad de generalización (etapa de chequeo).

CAPITULO 7

MODELO ADAPTATIVO DE INTELIGENCIA ARTIFICIAL (MAIA).

Con base en la exploración del estado del arte del tema que se describió en el capítulo 2 y los criterios de selección descritos en el capítulo 4 se escogieron para la investigación del prototipo del modelo MAIA las siguientes técnicas de IA: ANFIS (Adaptive Neuro-Fuzzy Inference Systems [46-49]), NN (Neural Networks [50-67]) y ART2 (Adaptive Resonance Theory [10]).

7.1 Modelo ANFIS.

Se llevó a cabo un proceso de prueba de un modelo de clasificación ANFIS descrito en [49]. Este modelo fue creado por Jang y Sun y consiste en un sistema de inferencia difuso basado en redes adaptativas ANFIS (Adaptive Network-based Fuzzy Inference System).

Este sistema hace uso de una regla de aprendizaje híbrida para optimizar los parámetros del sistema Sugeno de primer orden [47,48]. Está compuesto de cinco capas. Cada capa es el componente del sistema de inferencia difuso y desarrolla diferentes acciones. Los parámetros de premisa y consecuentes se sintonizan apropiadamente utilizando el método de retropropagación (BP).

En la **Figura 8** se ilustra el algoritmo de clasificación de fallas estudiado en la presente investigación. Como se observa, se desarrolló utilizando ANFIS y las características de la falla (corrientes de fase RMS y corriente de secuencia cero). Se utilizó un modelo del tipo Sugeno y cuatro ANFIS (Sistema de Inferencia Difuso Neuro Adaptativo) tal como se ilustra en la **Figura 8**.

El algoritmo se compone de tres pasos básicos:

- Adquisición de las corrientes de fase.
- Cálculo de la corriente de secuencia cero.
- Deducción del tipo de falla usando ANFIS.

Si los resultados de la inferencia son cero, entonces significa una situación de no falla. Sin embargo, si los resultados de la inferencia no son cero, entonces la técnica indica ambas la presencia de falla y el tipo de falla.

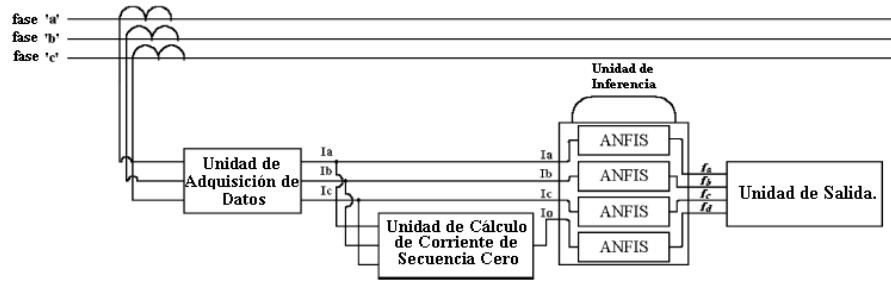


Diagrama del algoritmo de clasificación de fallas.

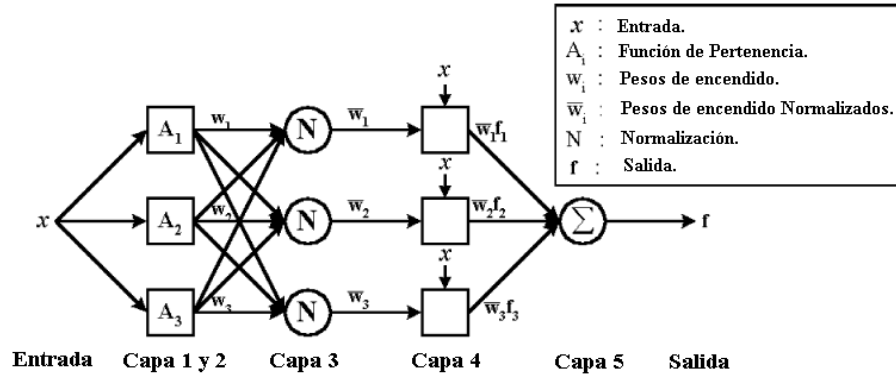


Figura 8. Diagrama del algoritmo de clasificación y de la arquitectura ANFIS utilizada.

La arquitectura adoptada para el modelo ANFIS, consistió de cinco capas y se utilizaron las siguientes tres reglas:

Regla 1:

Si x es A1 entonces $f1 = p1x + r1$.

Regla 2:

Si x es A2 entonces $f2 = p2x + r2$.

Regla 3:

Si x es A3 entonces $f3 = p3x + r3$.

Las diferentes capas se pueden describir de la siguiente forma:

Capa 1. Fuzzificación (pertenencia): Se seleccionó una función Bell generalizada luego de efectuarse un análisis de sensibilidad de agrupamiento sustractivo (mediante la función subclust de MATLAB) del cual se pudo determinar que la función Bell se adapta adecuadamente al universo de entrada considerado.

En MATLAB la función de pertenencia Bell generalizada se especifica de la siguiente manera:

$$GBELLMF(X, [A, B, C]) = 1./((1+ABS((X-C)/A))^(2*B));$$

Los parámetros A, B y C determinan la forma y posición de la función de pertenencia.

X representa los valores RMS de las corrientes de fase y corriente de secuencia cero para el algoritmo propuesto, y, las funciones de pertenencia utilizadas en ANFIS se ilustran en la **Figura 9** y **Figura 10**.

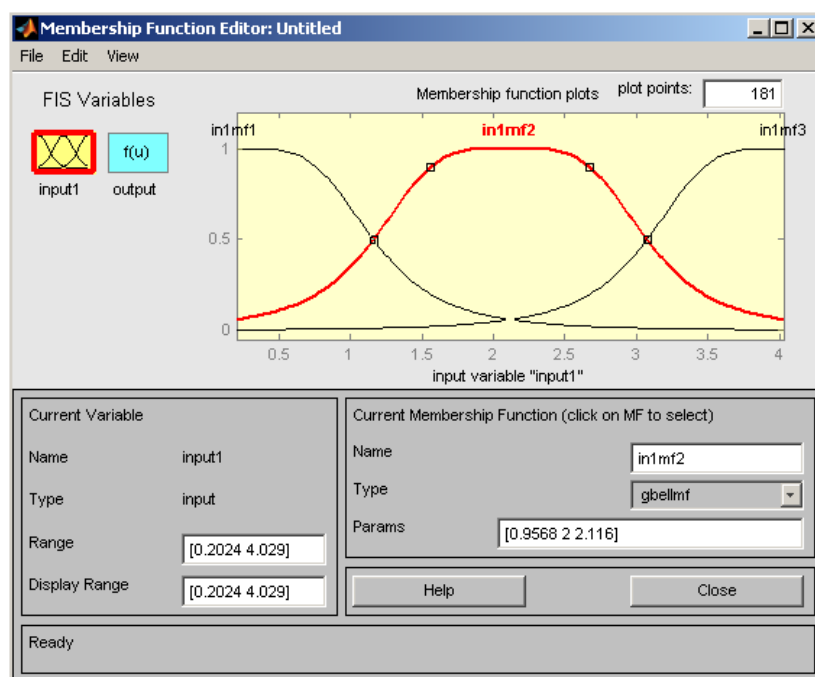


Figura 9. Función de pertenencia utilizada para la entrada de corriente de fase.

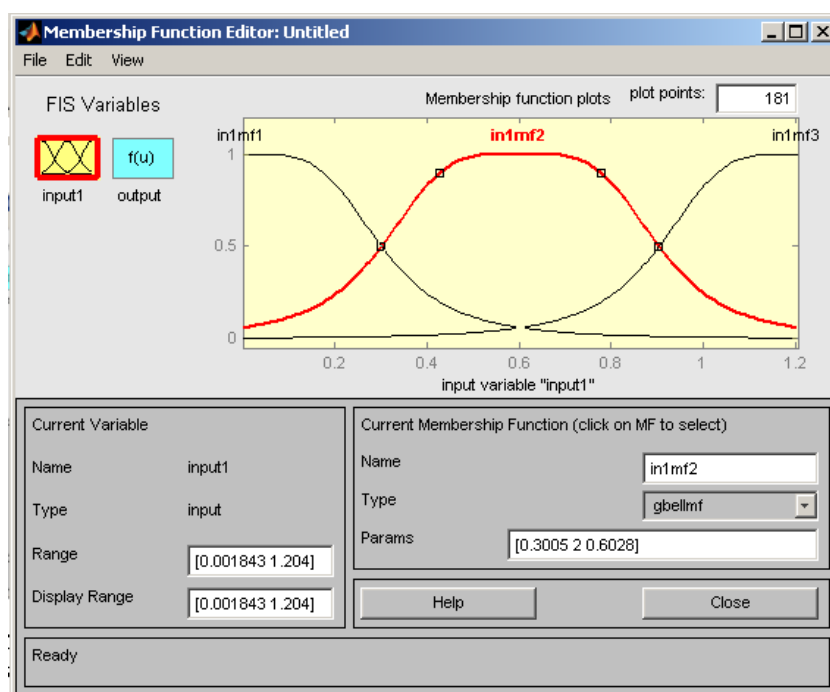


Figura 10. Función de pertenencia utilizada para la entrada de corriente de secuencia cero.

Capa 2. Conjunción: Cada nodo en esta capa multiplica las señales que entran cuando se trata de entradas múltiples. Sin embargo, dado que solamente se está considerando una sola entrada para el algoritmo propuesto entonces no se requiere realizar la multiplicación.

$$O_{2,i} = O_{1,i} \quad i = 1,2,3$$

Capa 3. Normalización: Esta arquitectura tiene tres reglas. Cada nodo en esta capa calcula la relación del peso de encendido de la i-ésima regla a la suma de todos los pesos de encendido de las reglas:

Ecuación 14
$$O_{3,i} = \overline{w}_i = \frac{w_i}{w_1 + w_2 + w_3}, \quad i = 1,2,3$$

Capa 4. Defuzzificación: Cada nodo i en esta capa es un nodo adaptativo con una función de nodo:

Ecuación 15
$$O_{4,i} = \overline{w}_i f_i = \overline{w}_i (p_i x + r_i)$$

Donde \overline{w} es la salida de la capa 3 y $\{p_i, r_i\}$ es el conjunto de parámetros.

Capa 5. Agregación: El único nodo de esta capa calcula la salida total como la suma de todas las señales que entran a este nodo.

Ecuación 16
$$O_{5,1} = f = (\overline{w}_1 x) p_1 + (\overline{w}_1) r_1 + (\overline{w}_2 x) p_2 + (\overline{w}_2) r_2 + (\overline{w}_3 x) p_3 + (\overline{w}_3) r_3$$

El modelo desarrollado consistió en cuatro ANFIS para las corrientes de fase ‘a’, ‘b’, ‘c’ y corriente de secuencia cero, respectivamente. Las entradas a la ANFIS son los valores RMS de las tres corrientes de fase y corriente de secuencia cero.

Los valores de salida significan cuatro categorías asociadas con las corrientes de fase ‘a’, ‘b’, ‘c’ y la corriente de secuencia cero. Si cualquiera de las salidas desde las tres primeras ANFIS (por ejemplo. Ia, Ib, Ic) es ‘1’ entonces esto indica una HIF, en el caso de ‘2’, es una LIF, y en el caso de ‘0’, no hay falla. Para las cuatro ANFIS (por ejemplo, Io) consideradas, ‘2’, ‘1’, ‘0’ significa una falla a tierra para LIF, HIF o una falla sin tierra, respectivamente, este criterio es presentando en la Tabla 3.

Tabla 3. Definición de las salidas de las ANFIS de acuerdo con el tipo de falla

Definición de Salidas.				
Tipo de Falla	SALIDA ANFIS			
	la	lb	lc	lo
SLG a	2	0	0	2
SLG b	0	2	0	2
SLG c	0	0	2	2
DLG ab	2	2	0	2
DLG bc	0	2	2	2
DLG ca	2	0	2	2
LL ab	2	2	0	0
LL bc	0	2	2	0
LL ca	2	0	2	0
3øG abc	2	2	2	0
HIF a	1	0	0	1
HIF b	0	1	0	1
HIF c	0	0	1	1
Sin falla	0	0	0	0

7.2 Modelos de Redes Neuronales.

Con el fin de seleccionar el modelo de red neuronal más apropiado para ser utilizado para la clasificación de fallas en un SEP se llevó a cabo una exploración de alternativas de modelos de redes neuronales basados en el estado del arte sobre el tema [50-67].

Se analizaron algunos modelos recientes, particularmente aquellos que utilizan aprendizaje combinado no supervisado/supervisado aplicado a la clasificación de fallas en líneas de transmisión: (i) red de retro-propagación (BP); (ii) red de mapeo característico (FM); (iii) red de función de base radial y (iv) red de cuantificación vectorial de aprendizaje (LVQ).

A continuación se describirán brevemente estos cuatro importantes clasificadores basados en redes neuronales. Se colocó especial énfasis en los principios básicos y diferencias en lugar que una descripción detallada en sí misma.

7.2.1 Clasificador de retro-propagación (BP).

Los clasificadores BP son las redes neuronales más populares y ampliamente aplicadas. Ellos se entrenan con supervisión usando el algoritmo del gradiente descendiente para minimizar el error entre las salidas reales y las salidas deseadas de la red.

En la **Figura 11** se ilustra la arquitectura general de este tipo de red.




Figura 11. Arquitectura general utilizada por el modelo de entrenamiento de retro-propagación.

En muchos artículos hay buenas introducciones a los métodos y aplicaciones exitosas de este tipo de redes neuronales aplicadas a los sistemas de potencia. Sin embargo, en general la mayor parte de los clasificadores BP son (1) de tiempo de entrenamiento prolongado; (2) difícil de seleccionar el tamaño óptimo y (3) potencialmente con tendencia a ser atrapados en un mínimo local [64].

Por este motivo, en años recientes se han desarrollado mejoras, particularmente en lo concerniente con el proceso de aprendizaje. En este sentido, es valioso mencionar los algoritmos de aprendizaje controlado difusos y el entrenamiento basado en algoritmos genéticos.

7.2.2 Clasificador de mapeo característico (FM).

Uno de los más importantes algoritmos de aprendizaje no supervisado es el mapeo característico autoorganizado propuesto por Kohonen que se ilustra en la Figura 12. El SOFM es usado para mapear vectores de entrada no supervisados en un espacio bidimensional donde los vectores son auto-organizados en grupos que representan las diferentes clases.

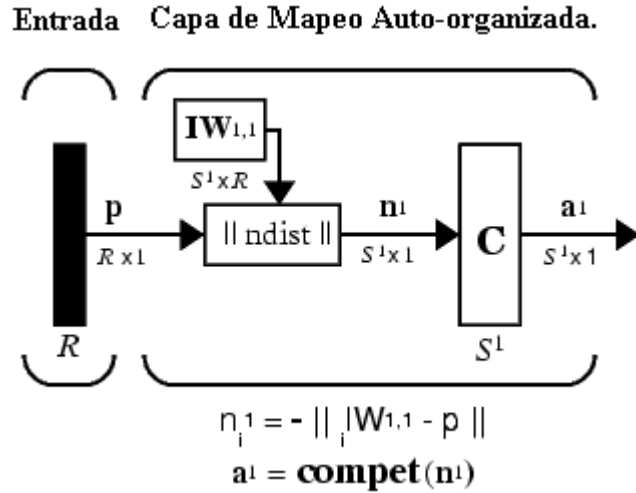


Figura 12. Arquitectura general utilizada por el modelo de Kohonen de SOMF.

El mapeo característico auto-organizado (SOFM) aprende a clasificar vectores de entrada de acuerdo a como ellos estén agrupados en el espacio de entrada. Este método difiere del método de capas competitivo en que las neuronas vecinas en el SOFM aprenden a reconocer además secciones vecinas en el espacio de entrada. Así entonces, los mapas auto-organizados aprenden tanto la distribución (como lo hace el método de capas competitivo) como la topología de los vectores de entrada que se entrenan. Las neuronas en la capa de un SOFM son organizadas originalmente en posiciones físicas de acuerdo a una función de topología. Las distancias entre neuronas se calculan desde sus posiciones con una función de distancia.

En estas redes no hay un target para la evaluación del error. Es decir, el aprendizaje de los pesos sinápticos es no supervisado, que significa que bajo la presentación de nuevos vectores de entrada, la red determina estos pesos dinámicamente de tal manera que los vectores de entrada que están estrechamente relacionados excitarán neuronas que están muy próximas o agrupadas [67]. Es capaz de separar datos en un número especificado de categorías y por tanto capaz de actuar como un clasificador. En la red Kohonen hay solamente dos capas una capa de entrada donde se colocan los patrones de las variables y una capa de salida que tiene una neurona para cada posible categoría o clase.

7.2.3 Clasificador de Función de Base radial (RBF).

La construcción de una RBF en su forma más básica considera tres capas enteramente diferentes, como se muestra en la **Figura 13**. La primera capa consiste de los nodos de entrada. La segunda capa está compuesta de los denominados nodos Kernel (capa de base radial) cuyas funciones son diferentes de las de una red de BP. Los nodos Kernel basados en las funciones de base radial

calculan funciones simétricas radialmente las cuales son un máximo cuando la entrada está cercana al centroide de un nodo. Los nodos de salida son simples sumas.




Figura 13. Arquitectura general utilizada por el modelo de RBF.

Esta arquitectura particular de RBF ha sido probada para mejorar el tiempo de entrenamiento pero a expensas de considerar muchos nodos en la capa de base radial y conexiones de pesos (en casos críticos el número de neuronas de esta capa puede llegar a ser igual al número de muestras de entrenamiento, es decir, una neurona por patrón de entrada).

7.2.4 Clasificador de cuantificación vectorial de aprendizaje (LVQ).

La red de LVQ es una forma de clasificador adaptativo cuya estructura es mostrada en la Figura 14. Este clasificador requiere una etapa final de entrenamiento supervisado para mejorar su desempeño. LVQ contiene una capa de entrada, una capa Kohonen y una capa de salida. El número de nodos de la capa de entrada es igual al número de parámetros de entrada. El número de nodos de la capa Kohonen está basado en el número de vectores de entrada en los datos de entrenamiento. La capa de salida contiene un nodo para cada clase. Algunas variaciones de LVQ se han propuesto para mejorar algunos defectos del LVQ básico. El LVQ1 se construye con un mecanismo de conciencia que es un bias de distancia que se adiciona a la distancia Euclidiana de los nodos de Kohonen con frecuencia para ganar más alta. El bias de distancia se determina basado en la diferencia entre la frecuencia para ganar de un nodo de Kohonen y el promedio de la frecuencia para ganar de un nodo Kohonen. El LVQ2 es utilizado para refinar una solución relativamente buena encontrada mediante un LVQ ó un LVQ1. En el presente análisis se utilizaron las funciones LVQ1 y LVQ2 de MATLAB.




Figura 14. Arquitectura general utilizada por el modelo de LVQ.

Con base en el análisis de los modelos anteriores (que se detalla en el Anexo D), la investigación se orientó por dos caminos:

- Complementar el modelo neuronal BP con un método de aprendizaje que permitiera mejorar la generalización y el error de clasificación resultante. Para ello se utilizó la metodología de regularización bayesiana (BR) descrita en [68-70].
- La búsqueda de un modelo Adaptativo que aprovechara las bondades de la combinación del aprendizaje no supervisado con el aprendizaje supervisado pero buscando a su vez suplir las debilidades encontradas en el método LVQ y RBF. Para ello se partió como base de la metodología utilizada por la tesis de doctorado de [Vasilic, 2004] consistente en la Teoría de Resonancia Adaptativa (ART).

7.3 Modelo de Red Neuronal BP con regularización Bayesiana.

Teniendo en cuenta las consideraciones del numeral anterior, se procedió a evaluar el desempeño de la red neuronal BP incorporándole técnicas adicionales de entrenamiento para mejorar su desempeño. Con el fin de lograr una alta capacidad de generalización de la red se consideró el enfoque conocido como regularización Bayesiana [68-70] en el que los pesos de la red se asumen como variables aleatorias con distribuciones específicas de manera que los parámetros de la regularización son asociados a las varianzas desconocidas asociadas a dichas distribuciones. De esta manera es posible estimar los parámetros empleando técnicas estadísticas. Una descripción más detallada de este enfoque y su combinación con otras técnicas puede encontrarse en [68].

En MATLAB es posible utilizar esta metodología por medio del algoritmo `trainbr` que puede pasarse como argumento a la hora de definir la red por medio de la función `newff`.

Para la detección y clasificación de la falla se utilizó una red feed-forward con una sola capa oculta de s neuronas [68-75]. Se consideraron 7 neuronas en la capa de entrada que corresponden con los valores rms de las tensiones y corrientes de las 3 fases más la corriente de secuencia cero. Para la capa de salida se consideraron 4 neuronas que corresponden a los valores binarios que indican la fase fallada (los 3 primeros bits) y si está o no aterrizada (último bit). En este caso el valor de s utilizado fue de 12 (valor que se obtuvo luego de realizar diversas pruebas de verificación buscando minimizar el error resultante pero a su vez garantizando un adecuado nivel de generalización).

El modelo general de esta red se ilustra en la **Figura 15**. Se utilizaron las funciones de activación de MATLAB `tansig` en la capa oculta y la de transferencia lineal `purelin` en la capa de salida.

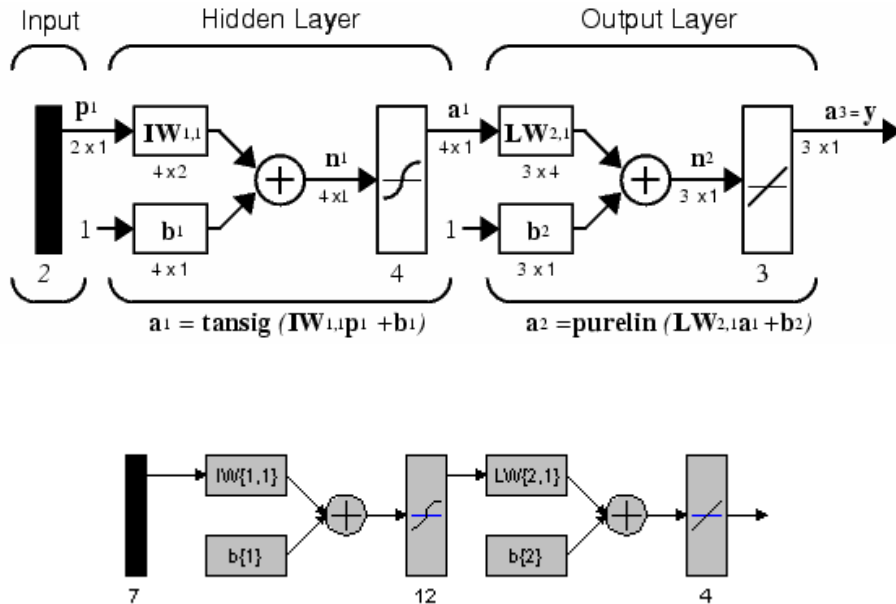


Figura 15. Diagrama del algoritmo de clasificación y de la arquitectura de red neuronal BR utilizada.

7.4 Modelo ART (Teoría de Resonancia Adaptativa).

El modelo ART no tiene una estructura típica definida con un número especificado de neuronas. En lugar de ello se compone de una estructura adaptativa con neuronas auto-envolventes. La estructura depende solamente de las características y orden de presentación de los patrones en el conjunto de datos de entrada. En la **Figura 16** se ilustra el diagrama del procedimiento completo utilizado para el entrenamiento de la red neuronal tipo ART.

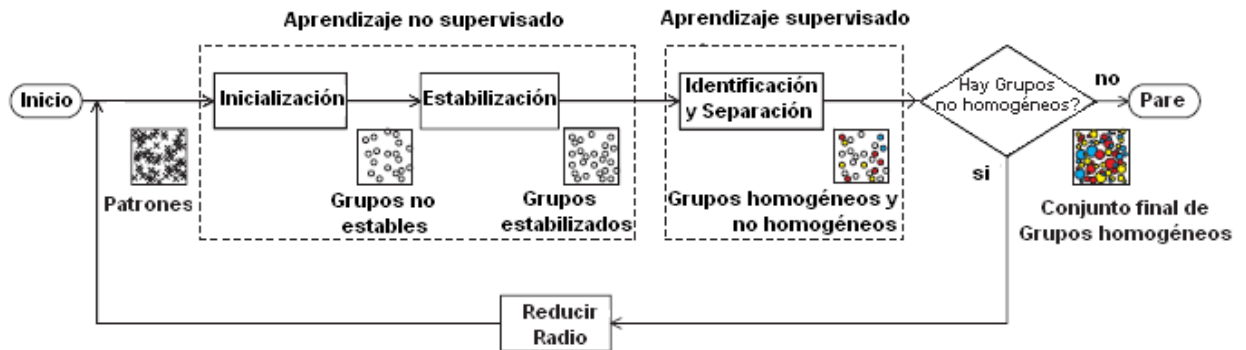


Figura 16. Aprendizaje de NN combinado no supervisado-supervisado [Kezunovic y Vasilic, 2004].

El entrenamiento consiste en realizar numerosas iteraciones en las etapas de aprendizaje no supervisado y supervisado, combinadas adecuadamente para lograr una eficiencia máxima. Los grupos de patrones similares se alojan en grupos,

definidos como hyper-esferas en un espacio multidimensional, donde la dimensión del espacio se determina mediante la longitud de los patrones de entrada. La red neuronal inicialmente utiliza aprendizaje no supervisado con patrones de entrada no etiquetados para formar grupos fugitivos inestables. Esto es un intento para descubrir la densidad de patrones mediante su agrupamiento en grupos para estimar prototipos de grupos que puedan servir como prototipos de los patrones de entrada típicos. Las etiquetas de categoría se asignan luego a los grupos durante la etapa de aprendizaje supervisado. El parámetro de sintonización llamado “umbral de vigilancia” ó “radio” controla el tamaño del grupo y por tanto el número de grupos generados, y es consecutivamente reducido durante las iteraciones. Si el umbral de vigilancia es alto, se pueden entonces incorporar muchos patrones diferentes dentro de un grupo y esto genera un pequeño número de grupos gruesos. Si el umbral de vigilancia es bajo, solamente activan el mismo grupo patrones que sean muy similares y esto genera un gran número de grupos finos. Posterior al entrenamiento, los centros de los grupos sirven como neuronas de la red neuronal típicos. La estructura de prototipos solamente depende de la densidad de los patrones de entrada. Cada patrón de entrenamiento ha sido ubicado en un único grupo, a la vez que cada grupo contiene uno ó más patrones de entrada similares. Un prototipo está centralmente localizado en el respectivo grupo, y es ya sea idéntico a uno de los patrones reales ó a un prototipo sintetizado de los patrones encontrados. Se asigna a cada grupo una etiqueta de categoría que simboliza una clase de grupos con una característica simbólica, significando que cada grupo pertenece a una de las categorías existentes. El número de categorías corresponde al número deseado de salidas de la red neuronal. Finalmente, durante la fase de implementación de la red entrenada, se calculan las distancias entre cada nuevo patrón y los prototipos establecidos y usando un clasificador difuso de los vecinos más cercanos se asigna la categoría más representativa al patrón en evaluación.

En la **Figura 17** se ilustra los pasos que se llevan a cabo para el mapeo del espacio de entrada en regiones de decisión de categorías usando el algoritmo ART2 propuesto por [Vasilic,2004]. Inicialmente, utilizando aprendizaje no supervisado/supervisado el espacio de los patrones de entrenamiento se transfiere dentro de un nivel de abstracción inicial, que contiene un conjunto de grupos con los prototipos, tamaño y categoría correspondientes. Posteriormente, los grupos son fuzzyficados y transformados en un nivel de abstracción intermedio. Por último, mediante la defuzzyficación se establecen las regiones de decisión refinadas y se obtiene un nivel de abstracción final.

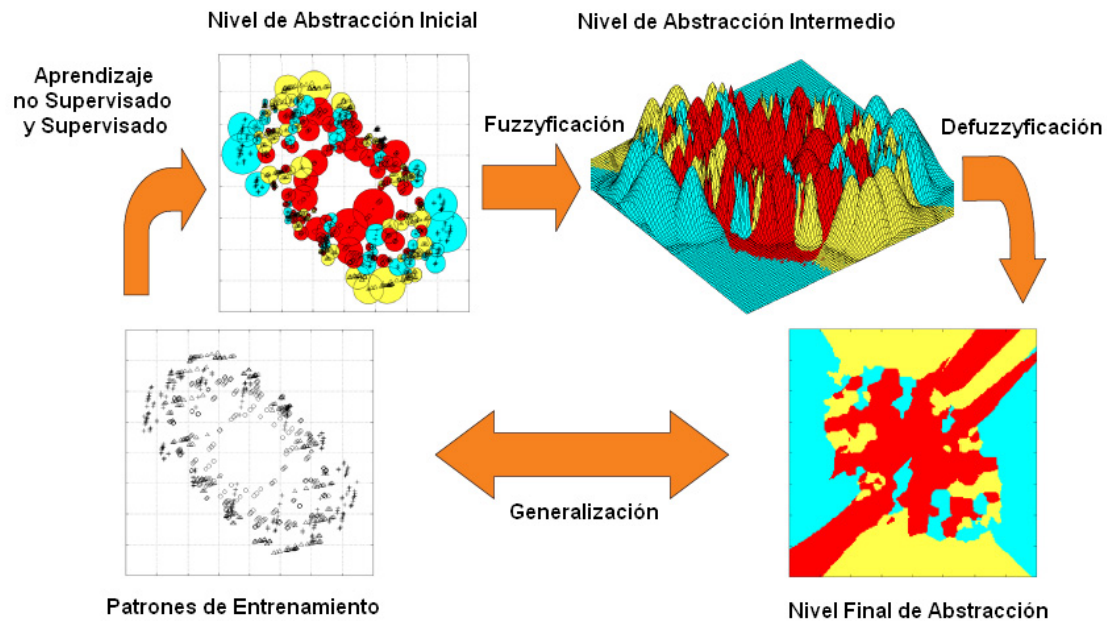


Figura 17. Mapeo del espacio de patrones en regiones de decisión de categorías usando entrenamiento no supervisado/supervisado, Fuzzyficación y defuzzyficación.

En la **Figura 18** se observa la clasificación que se obtiene de grupos homogéneos de una misma categoría utilizando la metodología de ART1 (la cual permite traslapes de grupos y la presencia de elementos en esta zona) y la que se obtiene mediante la metodología de ART2 (la cual reduce los radios hasta lograr que no hayan elementos en las zonas de traslape). Mediante esta modificación el modelo ART2 logra mejorar su desempeño con relación al error de clasificación ya que reduce la ambigüedad que se presenta cuando existen elementos en las zonas de traslape que pudieran producir clasificación errónea de algún patrón. No obstante, es importante anotar que a medida que se restringen más los radios se pierde capacidad de generalización de la red. El modelo ideal final es un compromiso entre las necesidades de precisión en la clasificación vs capacidad de generalización del modelo.




Figura 18. Comparación entre el modelo ART1 y el modelo ART2 (Kezunovic y Vasilic, 2004: [39]).

7.5 Modelo ART2 mejorado (reducción de radios y reentrenamiento en línea).

Como aporte de la presente investigación, el modelo ART2 de [Vasilic, 2004] fue mejorado introduciendo una metodología formal para la “reducción de los radios” y un concepto novedoso denominado “reentrenamiento en línea”.

7.5.1 Metodología formal para reducción de radios.

Con el fin de intentar resolver la ambigüedad que se presenta cuando existan clusters pertenecientes a diferentes categorías y con una región de intersección entre ellos no nula (es decir, que exista un cierto número de patrones de entrenamiento en esa región), [Vasilic,2004] propone una solución a este problema (ART2) consistente en introducir durante la fase de entrenamiento supervisado alguna regla para construir clusters homogéneos que cubran únicamente patrones de exactamente una categoría (regla de clusters homogéneos intersecados válida), permitiendo regiones de intersección entre clusters de diferentes categorías siempre y cuando no existan patrones en esas regiones.

En [Vasilic, 2004] se enuncia la metodología ART2 en lenguaje natural, pero no se describe formalmente el algoritmo ni se proporcionan detalles sobre su implementación. En el presente trabajo de tesis se desarrolló una propuesta formal para llevar a cabo la implementación del modelo de clasificación ART2 y lograr pasar de los clusters obtenidos con ART1 a los obtenidos con ART2, como se ilustra en la **Figura 11**. A continuación se presenta el procedimiento utilizado y la descripción formal del algoritmo implementado.

Regla de clusters homogéneos intersecados válidos.

Sea ch un cluster homogéneo de la forma $[r, P, C, CP]$.

donde:

r : es el radio del cluster. r pertenece a los Reales.

P : un vector de dimensión n , es el prototipo del cluster.

hallado con los patrones de entrenamiento; cada entrada de este vector pertenece a los reales.

C : es la clase del cluster, C perteneciente a los enteros.

CP : es un conjunto de vectores de dimensión n en donde cada entrada de cada vector pertenece a los reales, (patrones de entrenamiento que conforman el cluster)

Sea $@$: $[V1 \times V2 \rightarrow R]$ una función que entrega la distancia euclidiana entre dos vectores, donde $V1$ y $V2$ vectores de dimensión n .

Sea A un conjunto finito de clusters homogéneos sin patrones de entrenamiento en sus regiones de intersección, $A = \{a1, a2, a3, \dots, an\}$.

Sean $ch1[r1, P1, C1, CP1]$ y $ch2[r2, P2, C2, CP2]$ un par de clusters homogéneos.

Sea M el número de patrones en $CP1$.

Sea K el número de patrones en $CP2$.

Luego:

$ch1, ch2 \notin A$

SI Y SOLO SI:

$(P1 @ P2 < r1 + r2)$ y $(C1 \neq C2)$ y

PARA TODO $(cpm \in CP1)$ $\{ P2 @ cpm > r2 \}$ y

PARA TODO $(cpk \in CP2)$ $\{ P1 @ cpk > r1 \}$; $k = 1, 2, \dots, K$; $m = 1, 2, \dots, M$

Durante el entrenamiento supervisado (fase de estabilización), una vez obtenidos los clusters homogéneos debe verificarse que no existan patrones entre alguna región de intersección entre los clusters hallados, es decir que se cumpla la regla de clusters homogéneos intersecados válidos; si esta regla no se cumple se aplica la regla de reducción de radios, analizando la posibilidad de reducir el radio de alguno de los dos clusters en conflicto, o el de los dos si es necesario, asegurando no excluir ningún patrón, y de esta manera hacer que se cumpla la regla para luego añadir estos nuevos clusters optimizados al conjunto de clusters final.

Sea $\min() : [R^n \rightarrow R]$ una función que recibe un conjunto de reales y entrega el menor.

Sea $\max() : [R^n \rightarrow R]$ una función que recibe un conjunto de reales y entrega el mayor.

Si $ch1, ch2$ NO PERTENECEN A A

Se verifica si existen patrones de $ch1$ en $ch2$ y si es posible se hace la reducción de su radio.

```

1      si
2      EXISTE (cpm  $\in$  CP1) {  $P2@cpm < r2$  } ;  $m = 1, 2, \dots, M$ 
3      entonces
4           $r2_{max} = \min(P2@cpm=1, P2@cpm=2, \dots, P2@cpm=M)$ 
5           $r2_{min} = \max(P2@cpk=1, P2@cpk=2, \dots, P2@cpk=K)$ 
6          si  $r2_{min} > r2_{max}$ 
7              entonces
8                   $r2 = r2_{max} - (r_{max} - r_{min})/L$ 

```

Se verifica si hay patrones de $ch2$ en $ch1$ y si es posible se hace la reducción de su radio.

```

1      si
2      EXISTE (cpk  $\in$  CP2) {  $P1@cpk < r1$  } ;  $k = 1, 2, \dots, K$ 
3      entonces
4           $r1_{max} = \min(P1@cpk=1, P1@cpk=2, \dots, P1@cpk=k)$ 
5           $r1_{min} = \max(P1@cpm=1, P1@cpm=2, \dots, P1@cpm=M)$ 
6          si  $r1_{min} < r1_{max}$ 
7              entonces
8                   $r1 = r1_{max} - (r1_{max} - r1_{min})/L$ 

```

Donde L es una constante arbitraria inversa a la magnitud en que se reduce el radio.

Si se cumple la restricción dada en la línea 6 el radio puede reducirse y añadir el cluster al conjunto de clústeres homogéneos final.

Esta operación se realiza para todos los clusters homogéneos hallados luego de la estabilización y también contra los clusters homogéneos que se han añadido previamente en el conjunto A .

En las **Figura 19 a**

Figura 22 se muestra gráficamente lo que puede pasar en la intersección de los cluster.




Figura 19. A la izquierda dos clusters homogéneos no intersecados, a la derecha dos clusters homogéneos intersecados, sin patrones en esta región.




Figura 20. Dos clusters homogéneos intersecados, con patrones en esta región.

Nótese que en la **Figura 20** el cluster 2 (amarillo) no puede reducir su radio ya que excluiría el patrón más lejano, por este motivo estos patrones deben hacer parte de la siguiente iteración en el entrenamiento no supervisado – supervisado de ART. El cluster 1 puede reducir su radio, y es incluido en el conjunto de cluster final, esto es ilustrado en la

Figura 22.




Figura 21. Se aplica reducción de radios al cluster izquierdo y se descarta el derecho por que no es posible hacerlo.

7.5.2 Metodología de reentrenamiento en línea.

Mediante esta técnica se logra un modelo adaptativo que acomoda paulatinamente su estructura a los cambios que le va proporcionando el entorno real donde se desenvuelve. Es decir, cada vez que el algoritmo realice una clasificación errónea se tendrá la oportunidad de reentrenarlo con la clase apropiada suministrada por el experto. De esta manera el algoritmo irá aprendiendo cada vez más de las experiencias para irse mejorando durante su tiempo de vida. En las **Figura 23** a **Figura 26** se ilustra el procedimiento utilizado.




Figura 22. Clasificación errónea.




Figura 23. Selección de los K clústeres vecinos más cercanos.




Figura 24. Nuevo conjunto de patrones para el reentrenamiento




Figura 25. Conjunto de clústeres resultantes después del reentrenamiento en línea.

Inicialmente se preparan los patrones para el reentrenamiento, extrayendo el clúster que realizó la clasificación errónea (*Figura 23*) y los k clústeres vecinos más cercanos (*Figura 24*), para formar un conjunto reducido de patrones para reentrenamiento (*Figura 25*). Con este conjunto de patrones se realizan nuevamente las fases de aprendizaje no supervisado y aprendizaje supervisado ilustrado en la *Figura 16*. Esta vez el reentrenamiento es muy eficiente ya que desde el inicio se cuenta con un subconjunto reducido de clústeres y todos ellos homogéneos (el tiempo de reentrenamiento es del orden de unos cuantos segundos).

CAPITULO 8

ENTRENAMIENTO, VALIDACION Y CHEQUEO DE LOS MODELOS ANALIZADOS.

En este capítulo se presentan y analizan los resultados obtenidos del entrenamiento, validación y chequeo de los modelos analizados: ANFIS, Redes Neuronales (FM, BP, LVQ, RBF), red neuronal con regularización Bayesiana (BR) y Teoría de Resonancia Adaptativa (ART2).

Una vez definidas las arquitecturas adecuadas para los modelos que se describieron en el capítulo 7 se procedió a realizar diversas pruebas considerando varios casos de condiciones eléctricas del sistema eléctrico de potencia. Se comenzó inicialmente con un número bajo de patrones de entrenamiento (2214) y a medida que se verificaba el desempeño de los algoritmos se comenzó a incrementar el número de patrones (12250) hasta llegar a verificar el desempeño de la red con un total de 36500 patrones de entrenamiento y 10496 patrones de validación y chequeo.

A continuación se presentan los resultados obtenidos para cada uno de los modelos considerados.

8.1 Modelo ANFIS.

En el numeral C.1 del Anexo C se presentan los resultados obtenidos y las conclusiones que se derivaron del análisis preliminar que se realizó al modelo ANFIS con 508 patrones para entrenamiento y 246 patrones para validación y chequeo y en el numeral C.2 del Anexo C se presentan los resultados finales obtenidos al considerar 2214 patrones de entrenamiento de un mayor grado de dificultad que los patrones iniciales.

De este análisis se encontró que el modelo ANFIS utilizado presenta inconvenientes de adaptabilidad debido a que solamente utiliza una única variable de entrada para generar una correspondiente salida. Es decir, este modelo se desempeña muy bien si las corrientes (Ia, Ib e Ic) presentan variaciones significativas entre ellas (como sucedió con los casos del análisis preliminar). Sin embargo, cuando las corrientes tienden a parecerse entre sí el algoritmo no es capaz de identificar estas diferencias sutiles y tiende irremediablemente a clasificar erróneamente el tipo de falla (como sucedió con los casos del análisis final).

8.2 Modelos de redes neuronales (FM, BP, LVQ, RBF).

En el Anexo D se describe con detalle cada uno de estos modelos y los resultados obtenidos del análisis comparativo realizado a los cuatro modelos.

En resumen, del análisis realizado se obtuvieron las siguientes conclusiones:

- Las redes neuronales basadas en el aprendizaje exclusivamente no supervisado (como las de mapeo característico FM) son las que presentaron el menor desempeño en cuanto al error de clasificación resultante. El motivo de este resultado se fundamenta en que las clases asociadas con el tipo de falla se encuentran distribuidas en el espacio de una manera no uniforme y por tanto la clasificación se dificulta cuando solamente se utiliza como criterio las similitudes o cercanías entre patrones.
- De otro lado, las redes neuronales basadas en el aprendizaje exclusivamente supervisado (como las de retro-propagación BP) resuelven la dificultad asociada con las redes no supervisadas ya que mediante los target de salida se define con exactitud la clase específica que debe aprender a distinguir cada patrón que se presente a la entrada del algoritmo. Sin embargo, una de las dificultades a afrontar en este tipo de metodología es encontrar los pesos óptimos que minimicen el error resultante. En muchas ocasiones las soluciones pueden caer en mínimos locales y afectar el error de clasificación. Además, una vez entrenada la red el modelo resultante se convierte en una caja negra que si bien cumple con la labor de mapear adecuadamente las entradas con las salidas deseadas, su estructura natural es de por sí rígida e inmodificable. Es decir, no tiene la facultad de continuar aprendiendo con el tiempo (a no ser de que se volviera a realizar nuevamente todo el proceso de entrenamiento, lo cual a nivel práctico es ineficiente) y ello hace que con el paso del tiempo tienda a volverse obsoleta.
- Una alternativa para sacar provecho de ambos métodos es utilizar la combinación de aprendizaje no supervisado con aprendizaje supervisado. En este caso se intenta aprovechar la potencialidad del agrupamiento natural no supervisado (basado en similitudes en el espacio) pero asistido por los target de salida para orientar al algoritmo hacia las clases deseadas.

Con esta metodología híbrida se logra una estructura entrenada de la cual se conoce la ubicación en el espacio de todos los patrones entrenados y los grupos a los cuales pertenecen. Este tipo de estructura tiene la gran ventaja de que se puede modificar levemente afectando solamente una determinada porción del espacio de entrada acorde con las experiencias que se van teniendo con los cambios en el entorno. Esto hace que el modelo se vaya re-entrenando en línea y aprenda a mejorar su estructura con el tiempo.

Una dificultad de esta metodología se encuentra asociada con el número de grupos que se requiera formar para lograr una adecuada clasificación de los patrones de

entrada. En este sentido, entre mayor sea la cantidad de grupos mayor será el tiempo de procesamiento requerido y menor la velocidad de respuesta del algoritmo.

- Del análisis realizado a los cuatro algoritmos considerados se concluye que el mapeo característico por sí solo (modelo auto-organizado) no es apropiado para proporcionar la clasificación de fallas a partir de registros de osciloperturbografía. Sin embargo, si de alguna manera se lograra combinar la idea de similitud de este modelo auto-organizado (que se basa en la distancia Euclidiana) con algún procedimiento supervisado se podría lograr mejorar su desempeño.

De otro lado, si bien es cierto que la red neuronal BP tiene el inconveniente de ser una caja negra, no puede menospreciarse su potente capacidad como clasificador de patrones y a pesar de las dificultades asociadas con los mínimos locales durante el proceso de entrenamiento últimamente han surgido alternativas para aminorar este inconveniente [68-70].

Los otros dos modelos LVQ y RBF a pesar de que combinan aprendizaje no supervisado y supervisado y de que se obtuvieron buenos resultados para los casos considerados en el Anexo C mostraron no obstante algunas falencias relacionadas con su capacidad para adaptarse a diversas condiciones eléctricas de un SEP real.

En el método LVQ se utiliza un criterio de distancia para definir la similitud entre grupos de patrones (aprendizaje no supervisado) y se establecen las clases mediante targets en la capa de salida (aprendizaje supervisado). El enlace entre la entrada y la salida se realiza mediante un procesamiento intermedio en las neuronas de la capa competitiva que son las encargadas de clasificar los patrones de entrada en subclases intermedias y a partir de éstas definir las clases correspondientes. Es decir, en la capa competitiva se determina una neurona ganadora y con base en ello se activa la salida correspondiente. Es decir, la salida de una de las neuronas será igual a uno (la correspondiente con la neurona ganadora) y las demás salidas serán iguales a cero. En el caso práctico, dependiendo de las características del SEP (por ejemplo, patrones de entrada de características similares pero que pertenezcan a clases diferentes) varias neuronas de la capa de distancia se pueden activar en valores cercanos pero a su vez asociados con diferentes clases de salida. En estos casos, el algoritmo tiende a fallar y a proporcionar una clasificación equivocada.

Finalmente, aun cuando el método RBF produjo un error de clasificación bajo (inferior al 7% para los casos considerados en el análisis del Anexo D) muestra dificultades de clasificación cuando los patrones de entrada se encuentran relativamente alejados de los prototipos considerados. Para intentar afrontar este inconveniente se debe proveer un mayor número de neuronas kernel el cual dependiendo de los patrones de entrada podría llegar ser numéricamente igual al número total de patrones de entrada. Es decir, con este algoritmo se podrían cubrir exactamente todos los patrones entrenados (garantizar error de entrenamiento igual a cero), pero a costa de un modelo con una gran cantidad de grupos (1 grupo/patrón de

entrada) y con muy baja capacidad de generalización ya que con cualquier desviación con relación a los centroides entrenados (superior al radio de entrenamiento) se obtendría una clasificación errada.

8.3 Modelo de Red Neuronal BP con regularización Bayesiana.

En el Anexo E se describe con detalle el modelo neuronal BP con regularización Bayesiana (BR) y los resultados obtenidos para los 46996 casos considerados.

Al utilizar una red neuronal con el algoritmo trainbr que contempla tanto regularización como finalización temprana se obtuvieron resultados muy satisfactorios con errores inferiores al 1% para los 46996 patrones simulados con el ATP de acuerdo a las características del SEP administrado por ISA.

Cabe anotar que los errores mencionados en el párrafo anterior fueron calculados como una ponderación entre los errores de entrenamiento, validación y chequeo, medidos a su vez como la diferencia porcentual entre la salida de la red y el target real.

$$\text{Error} = \alpha_1 * \text{error entrenamiento} + \alpha_2 * \text{error validación} + \alpha_3 * \text{error chequeo}$$

$$\text{Donde } 0 \leq \alpha_1, \alpha_2, \alpha_3 \leq 1 \text{ y } \alpha_1 + \alpha_2 + \alpha_3 = 1$$

Los valores escogidos para α_1 , α_2 y α_3 fueron 0.2, 0.4 y 0.4 respectivamente con el fin de darle más peso a los errores de validación y chequeo, buscando precisamente la generalización y la robustez.

Los gráficos de la evolución del error y el contraste entre la salida de la red y los targets para el caso de la clasificación del tipo de falla se presentan en *la Figura 26 y Figura 27*.

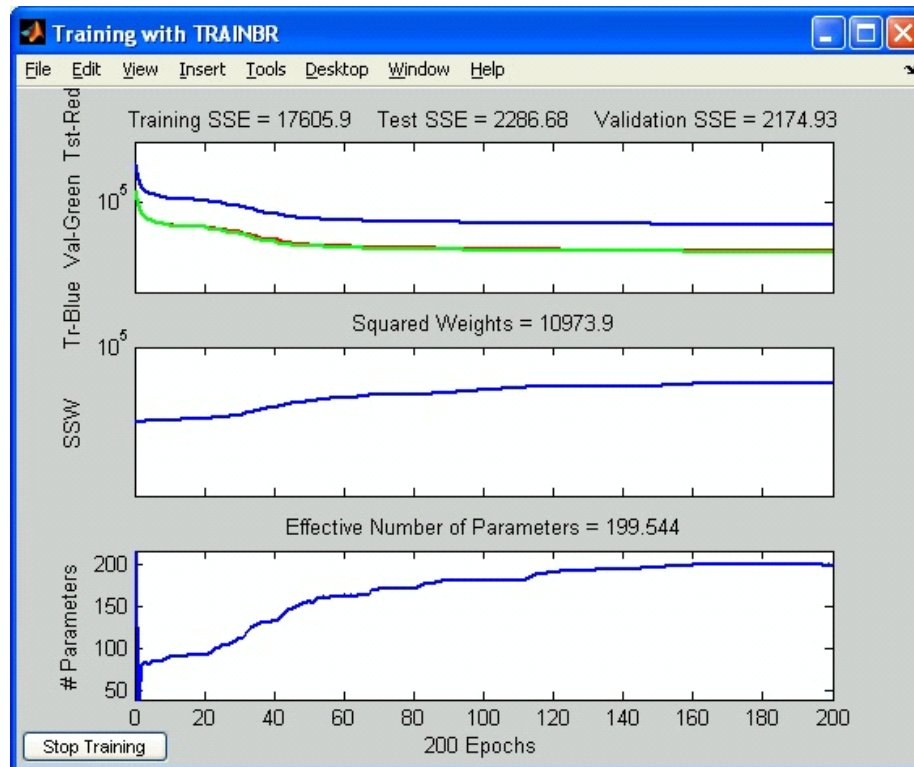


Figura 26. Evolución del entrenamiento para la clasificación del tipo de falla.

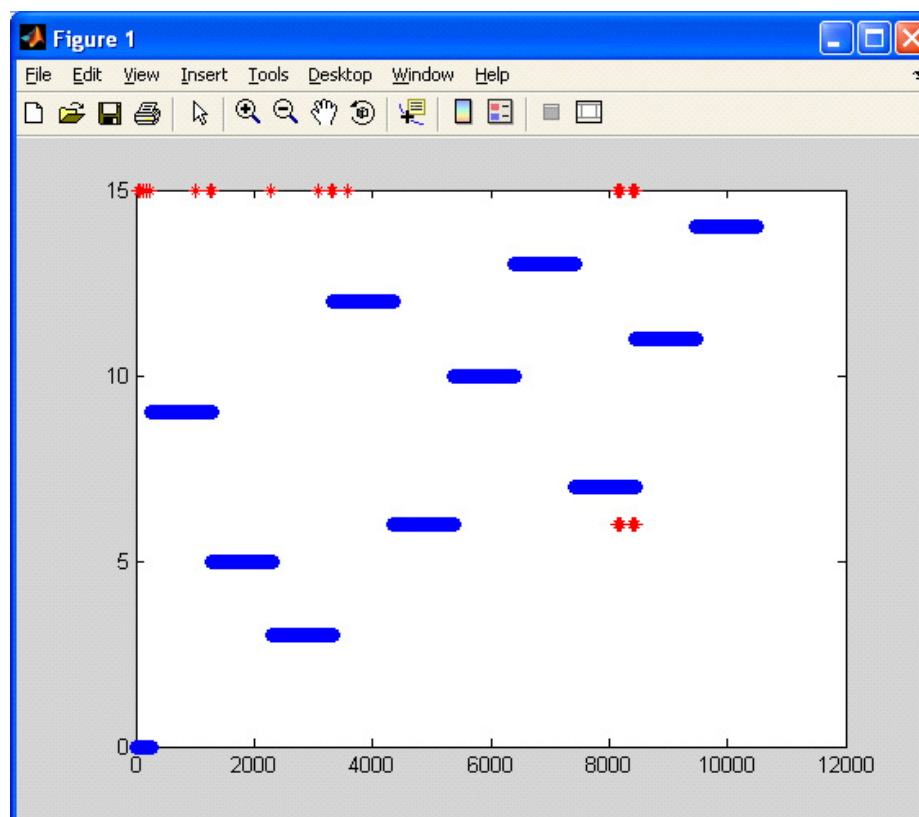


Figura 27. Salida de la red vs. targets para la clasificación del tipo de falla.

8.4 Modelo ART (Teoría de Resonancia Adaptativa).

En el Anexo F se presentan los resultados de las simulaciones realizadas mediante el modelo de teoría de resonancia adaptativa. Se realiza sensibilidad con relación a la técnica de procesamiento de señal (valores rms y con valores de onda completa “full-wave”) y el número de patrones utilizados para el entrenamiento, validación y chequeo.

8.5 Conclusiones del análisis realizado.

Del análisis realizado se encontró que el modelo ANFIS no responde adecuadamente a las exigencias de un SEP real ya que los errores obtenidos fueron altos (del orden del 48% para el entrenamiento y 60% para la validación).

De otro lado, los resultados obtenidos tanto con el modelo de red neuronal BR como con el modelo ART2 fueron muy satisfactorios y para los 46996 casos arrojaron errores de clasificación bajos (inferiores al 1% para el entrenamiento y al 4% para la validación).

CAPITULO 9

SISTEMA BASADO EN CONOCIMIENTO.

Con el fin de ensamblar la estructura básica del diagnóstico automático de fallas a partir de registros de osciloperturbografía se diseñó, construyó y validó un Sistema Basado en Conocimiento (SBC) para representar los diferentes estados de un registro e integrar en un mismo sistema el conocimiento extraído del Modelo Adaptativo de Inteligencia Artificial (MAIA) y las Meta-reglas asociadas con el disparo de las transiciones entre estados.

La metodología utilizada intenta emular dos aspectos del cerebro humano: hardware+software. De un lado, el hardware ó conocimiento almacenado en sistemas conexionistas (redes neuronales y ART) para reproducir algunas de sus capacidades asociadas a la inteligencia, especialmente la que se denomina de bajo nivel, relacionada con el reconocimiento de patrones, percepción, entre otros (modelo MAIA) y de otro, el software ó conocimiento intuitivo propio de los expertos de análisis de perturbaciones tratando de reproducir las capacidades de más alto nivel, especialmente la de razonamiento aproximado (Meta-reglas definidas por los expertos para la transición de estados en el SBC). En la **Figura 28** se ilustra el modelo utilizado para representar los estados de un registro de osciloperturbografía. Como se observa, en las transiciones se incorporan Meta-reglas para el cambio de estados: unas son reglas del hardware (modelo MAIA) para la detección del estado estacionario y los estados de falla y las demás son Meta-reglas del software para la detección de los demás estados del registro. En el Anexo G se describe la metodología utilizada para definir las diferentes Meta-reglas del experto.

En términos generales, el principio de funcionamiento de este SBC es el siguiente: Las señales de tensiones y corrientes del registro de osciloperturbografía debidamente filtradas (analógica y digitalmente) son presentadas al SBC de manera secuencial en el tiempo y son utilizadas por éste para ir determinando paulatinamente los diferentes tópicos relacionados con el diagnóstico automático de fallas. Una vez efectuado el barrido de todo el registro, se puede generar un reporte con la respectiva descripción del diagnóstico acorde con el flujo de estados específico que se haya presentado durante el evento.

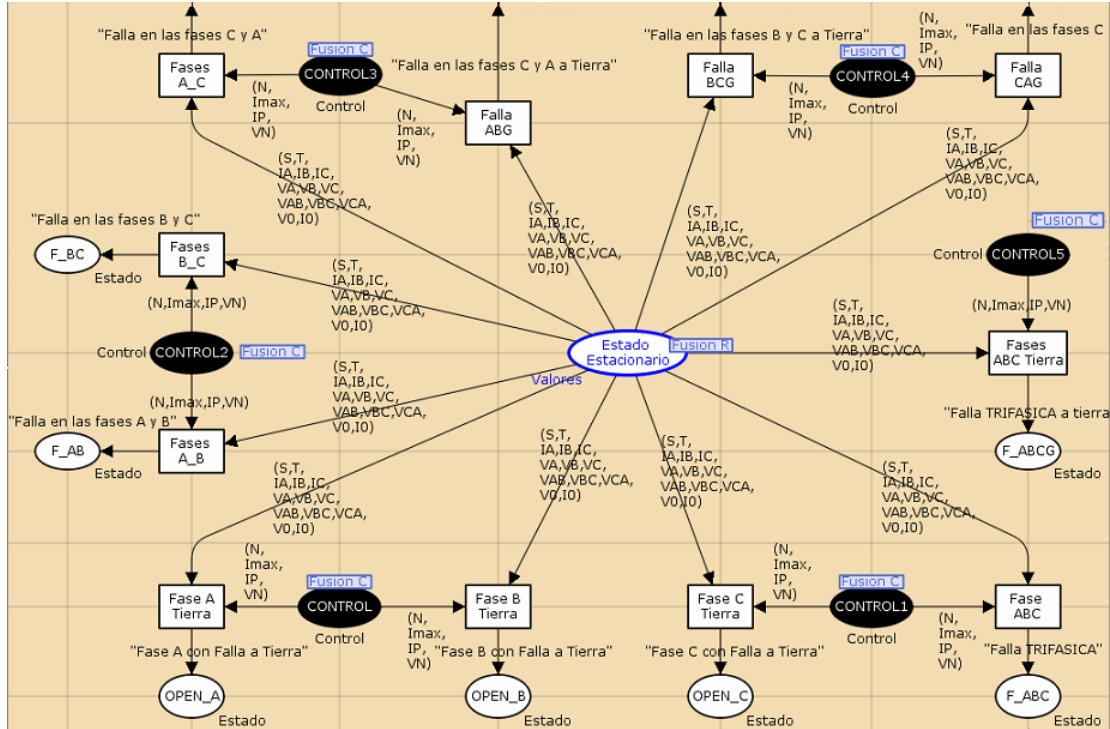


Figura 28. Sistema Basado en Conocimiento para modelar los estados de un registro.

Con el fin de integrar las reglas del diagnóstico de fallas descritas en el Anexo G se analizaron dos alternativas: una modelación basada en redes de Petri Coloreadas y otra basada en la definición de reglas y hechos en un lenguaje declarativo JESS(Java Expert System Shell).

Los resultados obtenidos con ambos métodos fueron muy satisfactorios y muestran que el Sistema Basado en Conocimiento responde de manera adecuada, es decir, realiza la transición entre estados acorde con los lineamientos suministrados por el modelo MAIA (estados de falla) y las Meta-reglas definidas por los expertos para los demás estados del registro. En los Anexos H y I se describe con detalle la metodología utilizada y los resultados obtenidos con ambos métodos.

CAPITULO 10

CONCLUSIONES Y TRABAJO FUTURO

10.1 Conclusiones.

La investigación realizada se enfocó en los siguientes aspectos fundamentales: técnicas de filtrado de señal, técnicas de preprocesamiento y normalización de los datos, extracción de características del SEP, selección y caracterización de técnicas de inteligencia artificial para el modelo MAIA y finalmente la integración mediante el SBC.

- De las técnicas de filtrado analizadas se concluyó que para su aplicación al procesamiento de registros de osciloperturbografía el filtro Butterworth de segundo orden y frecuencia de corte de 360 Hz es el adecuado para el filtrado analógico y el filtro de Fourier para el filtrado digital.
- Con relación a las técnicas de preprocesamiento y normalización de los datos que se analizaron (escalamiento, PCA e ICA), el procesamiento con valores rms combinado con escalamiento de señal produjo el mejor desempeño en cuanto al error de clasificación resultante en los algoritmos de IA analizados.
- Por su parte, los resultados de la investigación muestran que la metodología propuesta para la exploración sistemática de las condiciones eléctricas es amplia y robusta. Es decir, los patrones de entrenamiento, validación y chequeo que se obtienen con este método (siempre y cuando se generen de una forma adecuadamente espaciados) permiten abarcar de una manera efectiva el universo de entrada de condiciones eléctricas esperadas durante fallas en cualquier SEP real del mundo ya que permite reproducir cualquier escenario sintonizando adecuadamente los parámetros considerados por el modelo.
- Los resultados de la evaluación realizada a las técnicas de IA analizadas mostraron que el modelo ANFIS no es adecuado para la clasificación de fallas en un SEP real ya que se obtienen errores altos incluso en el entrenamiento (48.6%) mientras que con los modelos de red neuronal BR y ART 2 se obtienen errores de entrenamiento inferiores al 1% y de validación inferiores al 4%. Cabe resaltar, que a pesar de que el modelo neuronal BR ofrece errores un poco más bajos que el modelo ART2, presenta el inconveniente de ser una caja negra fija y rígida (es decir, la red neuronal simplemente evalúa sus entradas y produce sus salidas pero no se sabe cómo). Por este motivo, cuando se presenta una clasificación errada no hay manera de realizar modificaciones mínimas en alguna región específica y la red debe ser re-entrenada completamente lo cual es inapropiado a nivel práctico. Este inconveniente, no lo tiene el modelo ART2 ya que por su naturaleza se conoce la ubicación de todos los patrones y sus grupos asociados. Lo anterior motivó a la presente investigación a

introducir una mejora al modelo ART2 de [Vasilic,2004] consistente en el re-entrenamiento en línea con lo cual se logró un modelo Adaptativo a los cambios que se van presentando en el SEP durante su vida útil. Los resultados obtenidos con esta modificación propuesta fueron satisfactorios y validaron la metodología utilizada.

- Los resultados de la validación realizada al SBC mediante Redes de Petri Coloreadas y JESS fueron satisfactorios para ambos métodos aun cuando éste último mostró una mayor velocidad de respuesta.
- Finalmente, los resultados satisfactorios obtenidos de las pruebas realizadas, con 46996 casos simulados y alrededor de 3600 registros reales de ISA a todo el conjunto integrado: MAIA+SBC, validaron el método propuesto en la presente investigación.

10.2 Trabajo futuro.

En el presente trabajo de investigación se enfatizó en la búsqueda de un Modelo Adaptativo de Inteligencia Artificial para la clasificación del tipo de falla, la detección de la falla y la direccionalidad de la falla. Como trabajos de investigación futuros se podría continuar con otros tópicos del diagnóstico automático de fallas como son la identificación de la causa de la falla, la identificación del componente fallado y la localización de la falla.

REFERENCIAS.

- [1] [S. D. J. McArthur, 2004], E. M. Davidson, J.A. Hossack and J. R. McDonald. "Automating Power System Fault Diagnosis through Multi-Agent System". Technology Proceedings of the 37th Hawaii International Conference on System Sciences – 2004.
- [2] [M. Kezunovic, 2000] Fellow, IEEE. and X. Luo, Student Member, IEEE. "Automated Analysis of Digital Relay Data Based on Expert System". Department of Electrical Engineering, Texas A&M University, College Station, TX 77843-3128, USA. 2000.
- [3] [Sachdev, 2000]. "Design of a Distance Relay Using Adaptive Data Window Filters. Electrical and Computer Engineering, Canadian Conference on Volume 2, Issue, IEEE. 2000. Page(s):610 - 614 vol.2.
- [4] [Takami, 1999]. "Fuzzy Adaptive Fault Detector of Power Systems Based on Riccati Equation". Systems, Man, and Cybernetics, 1999. IEEE SMC apos;99 Conference Proceedings. 1999 IEEE International Conference on Volume 6, Issue , 1999 Page(s):179 - 184 vol.6.
- [5] [Butler, 1993]. "Detection And Classification of Line Faults on Power Distribution Systems Using Neural Networks". IEEE. Circuits and Systems, 1993., Proceedings of the 36th Midwest Symposium on Volume, Issue, 16-18 Aug 1993 Page(s):368-371 vol.1.
- [6] [Sidhu, 2004]. "A Comprehensive Analysis of an Artificial Neural-Network-Based Fault Direction Discriminator". IEEE TRANSACTIONS ON POWER DELIVERY, VOL. 19, NO. 3, JULY 2004.
- [7] [Jiang, 2003]. "A New Protection Scheme for Fault Detection, Direction Discrimination, Classification, and Location in Transmission Lines". Power Delivery, IEEE Transactions on Volume 18, Issue 1, Jan 2003 Page(s): 34 - 42.
- [8] [Sanaye, 1996]. "Power Transmission Lines Fault Direction Estimation using Artificial Neural Networks". Electrical and Computer Engineering, 1996. Canadian Conference on Volume 2, Issue , 26-29 May 1996 Page(s):758 - 761 vol.2
- [9] [Sidhu, 1995] and H. Singh, and M. S. Sachdev, "Design, Implementation and Testing of An Artificial Neural Network Based Fault Direction Discriminator For Protecting Transmission Lines". IEEE Trans. on Power Delivery , Vol. 10, No. 2, Apr. 1995, pp. 1002-1011.
- [10] [Vasilic, 2004]. "Fuzzy Neural Pattern Recognition Algorithm for classification of the events in power system networks". Power Delivery, IEEE Transactions on Volume 20, Issue 2, April 2005 Page(s): 1306 – 1314.

- [11] [Xu., 2002]. "Rough Set Methods in Power System Classification". Electrical and Computer Engineering, 2002. IEEE CCECE 2002. Canadian Conference on Volume 1, Issue , 2002 Page(s): 100 - 105 vol.1.
- [12] [Olescovicz, 2001]. "A Complete Scheme For Fault Detection, Classification and Location in Transmission Lines Using Neural Networks". Developments in Power System Protection, 2001, Seventh International Conference on (IEE) Volume , Issue , 2001 Page(s):335 – 338.
- [13] [Kumar, 1999]. "Fuzzy Approach to Fault Classification For Transmission Line Protection". TENCON 99. Proceedings of the IEEE Region 10 Conference Volume 2, Issue , Dec 1999 Page(s):1046 - 1050 vol.2.
- [14] [Wang, 1998]. "Fuzzy-Neuro Approach to Fault Classification For Transmission Line Protection". Power Delivery, IEEE Transactions on Publication Date: Oct 1998 Volume: 13, Issue: 4. On page(s): 1093-1104.
- [15] [Wang, 1997]. "Neural Network Approach to Power Transmission Line Fault Classification". Information, Communications and Signal Processing, 1997. ICICS., Proceedings of 1997 International Conference on Volume 3, Issue , 9-12 Sep 1997 Page(s):1737 - 1740 vol.3 IEEE.
- [16] [Kezunovic, 1996]. "Detect and Classify Faults Using Neural Nets". Computer Applications in Power, IEEE Volume 9, Issue 4, Oct 1996 Page(s):42 - 47.
- [17] [Chowdhury, 1996]. "Fault Classification Using Kohonen Feature Mapping". Intelligent Systems Applications to Power Systems, 1996. Proceedings, ISAP apos;96., International Conference on Volume , Issue , 28 Jan-2 Feb 1996 Page(s):194 – 198. IEEE.
- [18] [Ferrero, 1995]. "A Fuzzy Set Approach to Fault-Type Identification in Digital Relaying". Transmission and Distribution Conference, 1994., Proceedings of the 1994 IEEE Power Engineering Society Volume , Issue , 10-15 Apr 1994 Page(s):269 - 275.
- [19] [Mazon, 2001]. "Fault Location System On Double Circuit Two Terminal Transmission Lines Based On Ann's". Power Tech Proceedings, 2001 IEEE Porto Volume 3, Issue , 2001 Page(s):5 pp. vol.3.
- [20] [Salat, 2000]. "Fault Location in Transmission Line Using Self-Organizing Neural Network". Signal Processing Proceedings, 2000. WCCC-ICSP 2000. 5th International Conference on Volume 3, Issue , 2000 Page(s):1585 - 1588 vol.3. IEEE.
- [21] [Chen, 1997]. "An Artificial Neural Network Based Real-Time Fault Locator for Transmission Lines". Neural Networks,1997., International Conference on olume 1, Issue , 9-12 Jun 1997 Page(s):163 - 168 vol.1. IEEE.

- [22] [Altuve, 1996]. "Neural-Network-Based Fault Location Estimator For Transmission Line Protection". ISAI/IFIS 1996. Mexico-USA Collaboration in Intelligent Systems Technologies. Proceedings Volume , Issue , 1996 Page(s):186 – 191. IEEE.
- [23] [Xu, 2006]. "A Classification Approach for Power Distribution Systems Fault Cause Identification". IEEE Transactions on Power Systems, Feb. 2006 Volume: 21, Issue:1 On page(s): 53- 60.
- [24] [L.E Llano, 2000]. "Sistema de Información de la Gestión Operativa (SIGO)". Interconexión Eléctrica S.A. Medellín.
- [25] [ISA-UNAL,2004]. "Formulación plan piloto para diagnóstico automático de eventos". Interconexión Eléctrica S.A. Medellín.
- [26] [ISA-COLCIENCIAS-UNAL,2005]. "Herramientas informáticas para el diagnóstico automático de eventos en líneas de transmisión de energía eléctrica".
- [27] [Grisales, 2003]. "Sistema de Diagnóstico de fallas para Sistemas de Transmisión de Energía utilizando redes de Petri". Tesis de pregrado. Universidad Nacional. Medellín.
- [28] [Molina, 2004]. "Preprocesamiento de señales analógicas para la caracterización de fallas en líneas de transmisión con algoritmos de inteligencia artificial". Tesis de pregrado. Universidad Nacional. Medellín.
- [29] [IEEE Std C37.111-1999]. "IEEE standard Common Format for Transient Data Exchange (COMTRADE) for power systems.
- [30] Patiño, Diana. "MODELAMIENTO DE PROCESAMIENTO DE SEÑALES APLICADO A PROTECCIONES DISTANCIA EMPLEANDO MATLAB Y/O SIMULINK". Informe de práctica de estudiante. Interconexión Eléctrica S.A.
- [31] Chaudhary, R. Wilson, M. Glinkowski, M. Kezunovic, L. Kojovic, J. Martínez, "Modeling and Analysis of Transient Performance of Protection Systems using Digital Programs", General Systems Subcommittee (1994-2000)
- [32] Ambardar A., "Procesamiento de señales analógicas y digitales", Segunda Edición, Ed. Thomson Learning, México D.F, 2002.
- [33] S. Mitra, Digital Signal Processing. A Computer-Based Approach, Second Edition, Mc. Graw Hill, New York, 1998.
- [34] S. Mitra, Digital Signal Processing Laboratory Using MATLAB, Mc. Graw Hill, New York, 1999.

- [35] Díaz I., Altuve J., Vásquez E., “Estudio comparativo de filtros analógicos pasabajos para relevadores digitales de distancia”, VIII Reunión de Verano de Potencia del IEEE Sección México, Acapulco, Gro., Julio de 1995.
- [36] Kezunovic, Mladen and Slavko Vasilic. “Fuzzy ART Neural Network Algorithm for Classifying the Power System Faults”. IEEE TRANSACTIONS ON POWER DELIVERY, VOL. 20, NO. 2, APRIL 2005.
- [37] Y.H. Song a, Q.X. Xuan y A.T. Johns. “Comparison studies of five neural network based fault classifiers for complex transmission lines”. Electrical Power and Energy Systems. Elsevier. 43 (1997) 125-132.
- [38] Jolliffe, I.T., “Principal Component Analysis”, New York: Springer-Verlag, 1986.
- [39] Andrzej Cichocki and Shun-ichi Amari “Adaptive Blind Signal and Image Processing. Learning Algorithms and Applications. September 2002, Tokyo, Japan.
- [40] L. Tong, V. Soon, Y. F. Huang, and R. Liu, “Indeterminacy and identifiability of blind identification”. Circuits and Systems, IEEE Transactions on Volume 38, Issue 5, May 1991 Page(s):499 – 509.
- [41] L. Tong, Y. Inouye, and R. Liu, “Waveform-preserving blind estimation of multiple independent sources”, IEEE Trans. on Signal Processing, 41 (7), pp. 2461-2470, July 1993.
- [42] R. Szupiluk, “Blind Source Separation for Noisy Signals”, Ph.D. Thesis (in Polish), Supervisor A. Cichocki, Warsaw University of Technology, Poland, June 2002.
- [43] R. Szupiluk, A. Cichocki, “Blind signal separation using second order statistics”, Proc. of SPETO 2001, pp. 485-488.
- [44] Electromagnetic Transient Program (EMTP) - Rule Book, EPRI EL 6421-1, Electric Power Research Institute, Palo Alto, CA, June 1989.
- [45] Alternative Transients Program (ATP) - Rule Book, CanAm EMTP User Group, Portland, OR, Sep. 1992.
- [46] Hines JW. “MATLAB supplement to fuzzy and neural approaches in engineering”. New York: Wiley; 1997.
- [47] Jang JSR, Sun CT. “Neuro-fuzzy modeling and control”. Proc IEEE 1995;83(3):378–406.
- [48] Jang J.-S.R., -.Sun y E. Mizutani. “Neuro-Fuzzy and Soft Computing”. Ed. Prentice Hall, USA. 1997.

- [49] S.M. Yeo, C.H. Kima, K.S. Hong, Y.B. Lim, R.K. Aggarwal, A.T. John, M.S. Choid. "A novel algorithm for fault classification in transmission lines using a combined adaptive network and fuzzy inference system". *Electrical Power and Energy Systems* 25 (2003) 747–758. Elsevier.
- [50] M.A. El-Sharkawi and D. Niebur (editors), "Application of artificial neural networks to power systems," IEEE Tutorial Course Text 96TP112-0, Piscataway, NJ, 1996.
- [51] R. Aggarwal and Y. Song, "Artificial neural networks in power systems: Part I - General introduction into neural computing," *Power Engineering Jour.*, vol. 112, no. 3, pp. 129–134, June 1997.
- [52] R. Aggarwal and Y. Song, "Artificial neural networks in power systems: Part II - Types of artificial neural networks," *Power Engineering Jour.*, vol. 12, no. 1, pp. 41–47, Feb. 1998.
- [53] R. Aggarwal and Y. Song, "Artificial neural networks in power systems: Part III - Examples of applications in power systems," *Power Engineering Jour.*, vol. 12, no. 6, pp. 279–287, Dec. 1998.
- [54] M. Kezunovic, "A survey of neural net applications to protective relaying and fault analysis," *Engineering Intelligent Systems for El. Engr. and Comm.*, vol. 5, no. 4, pp. 185–192, Dec. 1997.
- [55] T. Dalstein and B. Kulicke, "Neural network approach to fault type classification for high speed protective relaying," *IEEE Trans. Power Delivery*, vol. 10, no. 2, pp. 1002–1011, Apr. 1995.
- [56] W.W. L. Keerthipala, C. T. Wai, and W. Huisheng, "Neural network based classifier for power system protection," *Electric Power Systems Research*, vol. 42, no. 2, pp. 109–114, Aug. 1997.
- [57] T. S. Sidhu, H. Singh, and M. S. Sachdev, "Design, implementation and testing of an artificial neural network based fault detection discriminator for protecting transmission lines," *IEEE Trans. Power Delivery*, vol. 10, no. 2, pp. 697–706, Apr. 1995.
- [58] A. L. O. Fernandez and N. K. I. Ghonaim, "A novel approach using a FIRANN for fault detection and direction estimation for high-voltage transmission lines," *IEEE Trans. Power Delivery*, vol. 17, no. 4, pp. 894–900, Oct. 2002.
- [59] T. Dalstein, T. Friedrich, B. Kulicke, and D. Sobajic, "Multi neural network based fault area estimation for high speed protective relaying," *IEEE Trans. Power Delivery*, vol. 11, no. 2, pp. 740–747, Apr. 1996.

- [60] F. Zahra, B. Jeyasurya, and J. E. Quaicoe, "High-speed transmission line relaying using artificial neural networks," *Electric Power Systems Research*, vol. 53, no. 3, pp. 173–179, Mar. 2000.
- [61] D. K. Ranaweera, "Comparison of neural network models for fault diagnosis of power systems," *Electric Power Systems Research*, vol. 29, no. 2, pp. 99–104, Mar. 1994.
- [62] D. V. Coury and D. C. Jorge, "Artificial neural network approach to distance protection of transmission lines," *IEEE Trans. Power Delivery*, vol. 13, no. 1, pp. 102–108, Jan. 1998.
- [63] Y. H. Song, Q. X. Xuan, and A. T. Johns, "Comparison studies of five neural network based fault classifiers for complex transmission lines," *Electric Power Systems Research*, vol. 43, no. 2, pp. 125–132, Nov. 1997.
- [64] Y.H. Song, A.T. Johns, R.K. Aggarwal, Computational Intelligence. "Applications in Power Systems, Science Press and Kluwer Academic", 1996.
- [65] T.S. Dillon, D. Niebur, "Artificial Neural networks Applications in Power Systems", CRN Press, 1996.
- [66] CIGRE TF 38-06-06 Report, D Niebur (Convener), "Artificial neural networks for power systems: A literature survey", *Eng. Intell. Syst.* 1 (3) (1993) 133-158.
- [67] Badrul H. Choudhury y Kunyu Wang. "Fault Classification Using Kohonen Feature Mapping". University of Wyoming. Electrical Engineering Department. 1996. IEEE.
- [68] [FoHa97] Foresee, F.D., and M.T. Hagan, "Gauss-Newton approximation to Bayesian regularization," *Proceedings of the 1997 International Joint Conference on Neural Networks*, 1997, pp. 1930-1935.
- [69] [HDB96] Hagan, M.T., H.B. Demuth, and M.H. Beale, *Neural Network Design*, Boston, MA: PWS Publishing, 1996.
- [70] MacK92] MacKay, D.J.C., "Bayesian interpolation," *Neural Computation*, Vol. 4, No. 3, 1992, pp. 415-447.